

LAPORAN
CUSTOMER SEGMENTATION DENGAN MENGGUNAKAN
ANALISIS RECENCY, FREQUENCY, DAN MONETARY
(RFM) (STUDI KASUS: AXA)



Disusun Oleh:
KELOMPOK 12 (SD-A2)

FAQIH SYAMIL	162112133006
MUHAMMAD YAHYA OKTAVIYANTO	164221005
BRAHMANTYA FIKRI SETYA PUTRA	164221034
MOCHAMMAD NAUFAL IZAH RAMADHAN	164221087
ANANDA ALVIN BERNERDIAN	164221196

SAINS DATA CONSULTING
PROGRAM STUDI S1
TEKNOLOGI SAINS DATA
DEPARTEMEN TEKNIK
FAKULTAS TEKNOLOGI MAJU DAN MULTIDISIPLIN
UNIVERSITAS AIRLANGGA
SURABAYA
2025

DAFTAR ISI

DAFTAR ISI.....	2
DAFTAR TABEL.....	4
DAFTAR GAMBAR.....	5
DAFTAR LAMPIRAN.....	6
BAB I	
PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah.....	2
1.3 Tujuan.....	2
1.3.1. Tujuan Umum.....	2
1.3.1. Tujuan Khusus.....	3
1.4 Manfaat.....	3
1.4.1. Manfaat Bagi Mahasiswa.....	3
1.4.2. Manfaat Bagi Universitas Airlangga.....	3
1.4.3. Manfaat Bagi Perusahaan.....	3
1.5 Batasan Masalah.....	4
BAB II	
TINJAUAN PUSTAKA.....	5
2.1 Customer Segmentation.....	5
2.2 Marketing Strategy.....	5
2.3 Produk Asuransi dan Pengembangan Produk.....	6
2.4 Recency, Frequency, and Monetary (RFM).....	7
2.5 Normalisasi Data Min-Max.....	9
2.6 Clustering.....	9
2.7 Elbow Method.....	10
2.8 Metode K-Means.....	12
2.9 Evaluasi Model.....	14
BAB III	
METODE PELAKSANAAN.....	16
3.1 Alur Kerja.....	16
3.2 Sumber Data.....	16
3.2.1 Deskripsi Dataset.....	17
3.3 Metode Penyelesaian Proyek.....	18
3.3.1 Data Understanding.....	18
3.3.2 Data Preprocessing.....	19
3.3.3 Exploratory Data Analysis.....	20
3.3.4 Features Engineering.....	20
3.3.5 Penentuan Jumlah Cluster Optimal.....	20

3.3.6 Modeling.....	21
3.3.7 Segmentasi Demografi.....	21
3.3.8 Evaluasi.....	21
3.3.9 Penyusunan Rekomendasi.....	21
3.4 Kontrak Kerja.....	21
3.5 Rincian Harga.....	21
3.6 Linimasa Proyek.....	21
BAB IV	
HASIL DAN PEMBAHASAN.....	23
4.1 Hasil Analisis Data.....	23
4.1.1 Data Understanding.....	23
4.1.2 Data Preprocessing.....	23
4.1.3 Exploratory Data Analysis (EDA).....	25
4.1.4 Feature Engineering.....	29
4.1.5 Penentuan Jumlah Cluster Optimal.....	30
4.1.6 Modeling dan Clustering.....	31
4.2 Pembahasan.....	32
4.2.1 Kombinasi 1.....	33
4.2.2 Kombinasi 2.....	35
4.3 Segmentasi Demografi.....	37
4.4 Rekomendasi Strategis untuk Perusahaan.....	38
BAB V	
KESIMPULAN DAN SARAN.....	42
5.1 Kesimpulan.....	42
5.2 Saran.....	43
DAFTAR PUSTAKA.....	45
LAMPIRAN.....	48

DAFTAR TABEL

Tabel 2.1 Kriteria Kebaikan Silhouette Score (Karo dkk., 2023).....	15
Tabel 4.1.6 Hasil Silhouette Score pada Setiap Kombinasi.....	32
Tabel 5.3 Deliverables.....	45
Tabel 5.4 Timeline Pengerjaan.....	45
Tabel 5.5 Harga Proyek.....	46

DAFTAR GAMBAR

Gambar 3.1 Alur Kerja.....	17
Gambar 4.1 Histogram Variabel Interaction with Customer Service.....	26
Gambar 4.2 Histogram Variabel Previous Claims History.....	27
Gambar 4.3 Histogram Variabel Coverage Amount.....	28
Gambar 4.4 Histogram Variabel Premium Amount.....	28
Gambar 4.5 Heatmap Correlation.....	29
Gambar 4.2.1 Cluster Kombinasi 1.....	35
Gambar 4.2.2 Cluster Kombinasi 2.....	37
Gambar 4.2.3 Cluster Kombinasi 3.....	39
Gambar 4.2.4 Cluster Kombinasi 4.....	40

DAFTAR LAMPIRAN

Lampiran 1. Kontrak Kerja.....	51
Lampiran 2. Project Summary.....	53
Lampiran 3 Rincian Harga.....	55

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi dan digitalisasi dalam industri keuangan, khususnya sektor asuransi, telah memberikan peluang besar dalam meningkatkan efisiensi operasional dan pelayanan berbasis data. Salah satu implementasi utama dari pemanfaatan data adalah penerapan customer segmentation, yaitu proses pengelompokan pelanggan berdasarkan kesamaan karakteristik, preferensi, atau perilaku mereka. Segmentasi pelanggan membantu perusahaan untuk merancang strategi pemasaran yang lebih tertarget dan personal, sehingga dapat meningkatkan loyalitas pelanggan dan profitabilitas perusahaan (Yum, Yoo, & Lee, 2022).

Namun, di banyak perusahaan asuransi, termasuk di Indonesia, praktik segmentasi masih banyak bergantung pada pendekatan tradisional berdasarkan intuisi agen atau demografi umum tanpa dukungan analitik data yang memadai. Hal ini menyebabkan hasil segmentasi yang kurang akurat dan sulit diimplementasikan secara konsisten. Studi oleh Yum et al. (2022) menemukan bahwa segmentasi di lapangan seringkali tidak selaras dengan data riil pelanggan dan gagal memberikan nilai tambah strategis.

Oleh karena itu, dibutuhkan penerapan metode analitik seperti clustering berbasis machine learning untuk menghasilkan segmentasi yang lebih akurat dan dapat diandalkan. Pendekatan seperti RFM (Recency, Frequency, Monetary) dan formal concept analysis (FCA) terbukti mampu mengungkap baik pengetahuan eksplisit maupun implisit dalam data pelanggan dan memberikan struktur hierarki segmentasi yang mudah dipahami oleh pengambil keputusan (Rungruang et al., 2024).

Selain itu, pada konteks perusahaan asuransi yang memiliki cakupan luas dan data pelanggan yang tersebar secara geografis seperti AXA Mandiri Jakarta, pendekatan distributed clustering berbasis arsitektur multi-tier super-peer P2P network dapat meningkatkan efisiensi proses segmentasi tanpa mengorbankan kualitas hasilnya (Manjunath & Kashef, 2021).

Berdasarkan studi-studi tersebut, segmentasi pelanggan tidak hanya mampu mengelompokkan berdasarkan nilai ekonomis, namun juga memungkinkan perusahaan untuk memahami perilaku pelanggan dengan lebih mendalam. Teknik seperti K-Means Clustering telah berhasil diterapkan dalam studi-segmen pelanggan asuransi jiwa dan menunjukkan efektivitas dalam mengidentifikasi kelompok seperti "Potential High-Value Customers", "Low Value Customers", dan "Disinterested Customers" (Abdul-Rahman et al., 2021).

Dengan latar belakang tersebut, proyek customer segmentation ini bertujuan untuk menerapkan metode clustering yang sesuai untuk mengelompokkan pelanggan AXA Mandiri Jakarta ke dalam segmen-segmen yang relevan. Hal ini diharapkan dapat membantu dalam merancang strategi pemasaran yang lebih tepat sasaran, mendukung pengembangan produk yang lebih sesuai dengan kebutuhan pelanggan, serta meningkatkan kepuasan dan loyalitas pelanggan secara keseluruhan.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, maka rumusan masalah dalam project ini adalah sebagai berikut:

1. Bagaimana pengelompokkan pelanggan AXA Mandiri Jakarta ke dalam segmen-segmen yang memiliki karakteristik serupa menggunakan metode K-Means?
2. Bagaimana penerapan RFM dalam membentuk segmentasi *customer*?
3. Bagaimana karakteristik hasil segmentasi pelanggan dapat membantu dalam merancang strategi pemasaran yang lebih tepat sasaran dan pengembangan produk yang sesuai kebutuhan setiap segmen?

1.3 Tujuan

1.3.1. Tujuan Umum

Menerapkan metode *customer segmentation* berbasis data untuk mengelompokkan pelanggan AXA Mandiri Jakarta agar dapat mendukung strategi pemasaran yang lebih tepat sasaran dan pengembangan produk yang sesuai kebutuhan masing-masing segmen.

1.3.1. Tujuan Khusus

1. Mengelompokkan pelanggan AXA Mandiri Jakarta ke dalam segmen-segmen berdasarkan karakteristik serupa menggunakan metode *clustering*.
2. Menganalisis hasil segmentasi pelanggan untuk membantu merancang strategi pemasaran dan pengembangan produk yang sesuai dengan kebutuhan setiap segmen.
3. Menerapkan *customer segmentation* dapat meningkatkan efektivitas *targeted marketing* serta retensi dan kepuasan pelanggan AXA Mandiri Jakarta.

1.4 Manfaat

1.4.1. Manfaat Bagi Mahasiswa

1. Meningkatkan keterampilan praktis dalam pengolahan dan analisis data menggunakan metode *clustering*.
2. Memahami penerapan data science dalam konteks bisnis asuransi nyata.
3. Mengembangkan kemampuan *problem solving* dan interpretasi hasil analisis untuk pengambilan keputusan bisnis.

1.4.2. Manfaat Bagi Universitas Airlangga

1. Menambah portofolio penelitian terapan yang relevan dengan kebutuhan industri.
2. Memperkuat hubungan dan kerja sama dengan perusahaan sebagai mitra riset dan praktik mahasiswa.
3. Meningkatkan kualitas pendidikan melalui pembelajaran berbasis proyek nyata.

1.4.3. Manfaat Bagi Perusahaan

1. Mendapatkan pemahaman yang lebih baik tentang karakteristik dan perilaku pelanggan.
2. Menyusun strategi pemasaran yang lebih efektif berdasarkan segmentasi pelanggan.
3. Meningkatkan loyalitas pelanggan dan potensi penjualan melalui produk yang disesuaikan dengan kebutuhan segmen.

1.5 Batasan Masalah

Agar penelitian dan analisis dalam project ini fokus dan terarah, maka batasan masalah yang ditetapkan adalah sebagai berikut:

1. Data yang digunakan dalam project ini terbatas pada data pelanggan AXA Mandiri Jakarta yang meliputi data demografis, informasi polis asuransi, dan perilaku pelanggan yang tersedia selama periode tertentu, misalnya dua tahun terakhir.
2. Metode *clustering* yang digunakan terbatas pada teknik yang dapat menangani data campuran numerik dan kategorikal, seperti *K-means* atau kombinasi algoritma serupa.
3. Analisis dan segmentasi pelanggan difokuskan pada tujuan pemasaran dan pengembangan produk, tanpa mengkaji faktor eksternal lain seperti kondisi ekonomi makro atau kompetitor.
4. Hasil segmentasi digunakan sebagai dasar rekomendasi strategi pemasaran targeted marketing dan pengembangan produk, namun implementasi dan evaluasi strategi tersebut di luar cakupan project ini.

BAB II

TINJAUAN PUSTAKA

2.1 Customer Segmentation

Segmentasi pelanggan adalah proses mengelompokkan pelanggan ke dalam sub kelompok yang memiliki kesamaan dalam hal kebutuhan, karakteristik, atau perilaku. Hal ini dilakukan untuk meningkatkan efektivitas strategi pemasaran dan pengembangan produk. Dalam penelitian-penelitian ini, segmentasi pelanggan tidak hanya dilakukan berdasarkan data demografis atau perilaku pembelian, tetapi juga mempertimbangkan fitur produk yang dihargai oleh pelanggan, baik itu melalui analisis ulasan produk online atau penggunaan model RFM (Recency, Frequency, dan Monetary). Segmentasi pelanggan yang didasarkan pada ulasan produk online menggunakan machine learning yang dapat dijelaskan memberikan keuntungan dalam mengidentifikasi kelompok pelanggan dengan kebutuhan yang belum terpenuhi, yang lebih relevan untuk pengembangan produk baru (Joung & Kim, 2023). Di sisi lain, segmentasi berbasis RFM lebih fokus pada pola perilaku pembelian pelanggan yang telah terbukti efektif di sektor ritel untuk merancang strategi pemasaran yang lebih tepat sasaran dan meningkatkan retensi pelanggan (Wang, 2022; Rungruang et al., 2024; Anitha & Patil, 2022).

2.2 Marketing Strategy

Strategi pemasaran adalah pendekatan yang dirancang oleh perusahaan untuk memaksimalkan daya tarik produk atau layanan mereka kepada target pasar. Tujuan dari strategi ini adalah untuk menciptakan nilai lebih bagi konsumen dengan cara menyesuaikan produk dan layanan yang ditawarkan sesuai dengan kebutuhan spesifik konsumen. Menurut Ma dan Gu (2024), dalam era ekonomi digital, perusahaan e-commerce harus mengembangkan strategi pemasaran yang berbasis pada data besar dan multi-channel agar dapat beradaptasi dengan perubahan kebutuhan konsumen dan menjaga perkembangan jangka panjang perusahaan. Strategi ini dapat mencakup berbagai aspek, mulai dari manajemen produk yang efektif hingga pemasaran yang dipersonalisasi melalui konten yang disesuaikan dengan audiens.

Segmentasi pelanggan tidak hanya penting untuk menargetkan iklan atau penawaran khusus, tetapi juga berperan dalam mendefinisikan bagaimana produk atau layanan diposisikan di pasar. Sebagai contoh, penggunaan big data dan analisis prediktif dalam industri e-commerce membantu perusahaan untuk merancang strategi pemasaran yang lebih efektif, serta untuk beradaptasi dengan perubahan preferensi konsumen yang cepat. Hal ini penting dalam menciptakan strategi pemasaran yang disesuaikan yang memungkinkan perusahaan untuk tetap kompetitif dalam pasar yang terus berkembang. Dalam dunia yang didorong oleh teknologi digital, pemasaran berbasis data, baik melalui pemasaran media sosial atau strategi berbasis AI, semakin memperkuat keterlibatan pelanggan dan meningkatkan efektivitas jangka panjang perusahaan (Ma & Gu, 2024; Gao et al., 2025)

2.3 Produk Asuransi dan Pengembangan Produk

Industri asuransi merupakan salah satu sektor penting dalam sistem keuangan yang berperan dalam memberikan perlindungan terhadap berbagai risiko yang tidak terduga, seperti kematian, kecelakaan, penyakit, dan kerugian harta benda. Produk asuransi sendiri berkembang dalam berbagai bentuk, mulai dari asuransi jiwa, kesehatan, kendaraan, properti, hingga asuransi berbasis investasi. Setiap jenis produk ditujukan untuk menjawab kebutuhan spesifik dari segmen pasar yang berbeda, tergantung pada faktor seperti usia, pendapatan, status pekerjaan, serta kondisi sosial ekonomi (Gao et al., 2025).

Dalam menghadapi persaingan industri yang semakin kompetitif dan perilaku konsumen yang terus berubah, perusahaan asuransi dituntut untuk terus melakukan inovasi produk. Proses pengembangan produk yang efektif tidak hanya ditentukan oleh keunggulan fitur atau manfaat polis, tetapi juga oleh seberapa dalam pemahaman perusahaan terhadap kebutuhan dan preferensi pelanggan. Studi oleh Joung dan Kim (2023) menunjukkan bahwa pemahaman terhadap pelanggan, termasuk melalui analisis ulasan produk atau interaksi historis, sangat penting dalam menciptakan produk yang relevan dan bernilai tambah.

Pelanggan masa kini semakin menuntut layanan yang cepat, fleksibel, dan personal. Oleh karena itu, pengembangan produk tidak bisa lagi dilakukan dengan pendekatan umum, tetapi harus berbasis pada segmentasi pasar yang akurat dan

berbasis data. Dengan memahami pola kebutuhan dan ekspektasi pelanggan secara menyeluruh, perusahaan dapat menyesuaikan desain produk, strategi komunikasi, serta penetapan harga agar lebih tepat sasaran. Hal ini tidak hanya meningkatkan efektivitas penjualan, tetapi juga berdampak positif terhadap loyalitas dan kepuasan pelanggan dalam jangka panjang (Ma & Gu, 2024).

2.4 Recency, Frequency, and Monetary (RFM)

Model RFM (Recency, Frequency, and Monetary) adalah pendekatan yang banyak digunakan dalam segmentasi pelanggan berbasis perilaku. Recency mengacu pada seberapa baru pelanggan melakukan pembelian, dengan semakin kecil nilai recency, semakin sering pelanggan berkunjung. Frequency mengukur seberapa sering pelanggan melakukan pembelian dalam periode tertentu, sementara Monetary menunjukkan jumlah uang yang dibelanjakan oleh pelanggan dalam periode yang sama. RFM sering digunakan untuk mengidentifikasi pelanggan yang paling berharga dan menetapkan strategi pemasaran yang lebih efektif berdasarkan perilaku mereka (Anitha & Patil, 2022).

Beberapa studi yang menggunakan RFM sebagai dasar segmentasi pelanggan telah membuktikan keefektifannya. Misalnya, penelitian yang diterbitkan oleh Rungruang et al. (2024) menggunakan kombinasi model RFM dan Formal Concept Analysis (FCA) untuk segmentasi pelanggan, memberikan wawasan yang lebih mendalam tentang hubungan antar data pelanggan, sehingga strategi pemasaran bisa lebih disesuaikan dengan karakteristik masing-masing segmen.

Selain itu, model RFM juga diterapkan dalam studi yang menggunakan algoritma K-Means untuk segmentasi data pelanggan e-commerce, dengan hasil yang menunjukkan bahwa segmentasi berbasis RFM dapat meningkatkan retensi pelanggan dan profitabilitas perusahaan dengan lebih tepat menargetkan pelanggan yang lebih sering bertransaksi dan membelanjakan lebih banyak (Wang, 2022)

a. Recency

Recency merupakan jarak dari waktu transaksi terakhir kali dilakukan dengan waktu atau tanggal yang ditetapkan untuk penelitian, dalam hal ini

tanggal yang ditetapkan untuk penelitian yaitu waktu setelah data transaksi dikumpulkan. Nilai *recency* diperoleh dengan persamaan seperti berikut.

$$R_i = t_p - t_i$$

Keterangan :

R_i : Nilai *recency* pada pelanggan ke-i

t_i : waktu transaksi yang terakhir kali dilakukan oleh pelanggan ke-i

t_p : waktu acuan yang ditetapkan untuk penelitian

b. *Frequency*

Frequency merupakan jumlah transaksi yang dilakukan selama periode tertentu. Nilai *frequency* didapatkan dengan menggunakan persamaan seperti berikut.

$$F_i = \sum_{j=1}^n a_{ij}$$

Keterangan :

F_i : Total jumlah transaksi (*frequency*) yang dilakukan oleh pelanggan ke-i

i : Pelanggan ke-i (misalnya, pelanggan pertama, kedua, dan seterusnya).

j : Transaksi ke-j

n : Total jumlah transaksi yang dilakukan pelanggan ke-i selama periode penelitian

a_{ij} : Pemesanan yang dilakukan oleh pelanggan ke-i pada transaksi ke-j

c. *Monetary*

Monetary merupakan total biaya yang dikeluarkan dalam periode tertentu. Nilai *monetary* didapatkan dengan persamaan seperti berikut.

$$M_i = \sum_{j=1}^n b_{ij}$$

Keterangan :

M_i : Total nilai *monetary* (total pengeluaran) yang dilakukan oleh pelanggan ke-i

i : Pelanggan ke-i (misalnya, pelanggan pertama, kedua, dan seterusnya).

j : Transaksi ke-j

n : Total jumlah transaksi yang dilakukan pelanggan ke-i selama periode penelitian

bi,j : Pengeluaran yang dilakukan pelanggan ke-i pada transaksi ke-j

2.5 Normalisasi Data Min-Max

Normalisasi adalah proses yang digunakan untuk memastikan konsistensi dan keakuratan data dengan membersihkan dan mengaturnya (Tressa dkk., 2024). Tujuan dari normalisasi data mencakup beberapa aspek penting, yaitu menghilangkan kerangkapan data, mengurangi kompleksitas, dan mempermudah modifikasi data (Perdana dkk., 2022). Salah satu metode normalisasi adalah normalisasi Min-Max. Normalisasi Min-Max merupakan salah satu metode normalisasi yang mengubah data ke dalam rentang 0 hingga 1. Metode ini memiliki beberapa kelebihan, yaitu nilai perbandingan antar data sebelum dan sesudah normalisasi tetap seimbang dan tidak menghasilkan data bias (Pramudiansyah & Munte, 2021). Berikut merupakan persamaan dari normalisasi min-max (Prasetyo dkk., 2020)

$$x'_i = \frac{x_i - x_{min}}{x_{max} - x_{min}}$$

Keterangan :

x'_i : Hasil normalisasi nilai data ke-i

x_i : Nilai awal data ke-i

x_{min} : Nilai terkecil (minimum) atribut

x_{max} : Nilai terbesar (maksimum) atribut

2.6 Clustering

Clustering merupakan salah satu metode unsupervised learning, dimana algoritma belajar untuk mengelompokkan data tanpa adanya label atau target yang telah ditentukan sebelumnya (Silamantha & Hadiono, 2024). Clustering merupakan teknik pengelompokan data dalam suatu himpunan dengan cara membaginya menjadi beberapa kelompok atau cluster yang berbeda. Tujuan utama dari proses ini adalah untuk meningkatkan keseragaman di dalam satu cluster (intraclass) serta meminimalkan kesamaan antar cluster yang berbeda (interclass). Dengan demikian, setiap objek dalam satu cluster memiliki kemiripan

yang tinggi satu sama lain, namun berbeda secara signifikan dari objek yang berada di cluster lain (Umargono dkk., 2019).

Algoritma clustering dirancang untuk menemukan pola kelompok dalam data dengan mendasarkan pada tingkat kemiripan antar objek. Hal ini juga berarti bahwa algoritma ini akan berupaya mengurangi kemiripan antara objek yang berada di cluster berbeda (Adiana dkk., 2018). Dalam praktik bisnis, teknik clustering sangat bermanfaat dalam proses segmentasi pelanggan, karena memungkinkan perusahaan untuk mengelompokkan pelanggan berdasarkan karakteristik yang serupa. Dengan demikian, strategi pemasaran yang disusun dapat lebih disesuaikan dan tepat sasaran untuk setiap segmen pelanggan.

Secara umum, metode clustering dibagi menjadi dua kategori utama berdasarkan struktur hasil pengelompokannya, yakni metode hierarki dan non-hierarki (partisi) (Oti dkk., 2021). Clustering hierarki membentuk kelompok secara bertahap berdasarkan ukuran kemiripan antar objek. Pendekatan ini terdiri atas dua jenis, yaitu aglomeratif (bottom-up) yang dimulai dari objek individu sebagai cluster tersendiri lalu digabungkan secara bertahap, serta divisif (top-down) yang dimulai dari satu cluster besar kemudian dibagi menjadi bagian-bagian yang lebih kecil. Proses ini biasanya divisualisasikan dalam bentuk dendrogram yang menggambarkan tahapan penggabungan atau pemisahan cluster beserta tingkat kemiripan atau jaraknya (Madhulatha, 2012).

Sementara itu, metode non-hierarki atau partisi bekerja dengan membagi data ke dalam jumlah cluster yang telah ditentukan sebelumnya. Algoritma ini melakukan proses iteratif untuk mengalokasikan kembali objek data ke dalam cluster hingga mencapai hasil yang stabil atau konvergen. Setiap cluster harus berisi minimal satu data, dan setiap data hanya bisa termasuk dalam satu cluster saja. Berdasarkan hasil evaluasi, metode partisi cenderung memiliki performa yang lebih baik dibandingkan metode hierarki karena membutuhkan komputasi yang lebih efisien dan memberikan hasil clustering yang lebih optimal (Garima dkk., 2015).

2.7 Elbow Method

Salah satu kelemahan utama dalam metode clustering partisi adalah tidak adanya aturan pasti untuk menentukan jumlah cluster (K) yang paling sesuai.

Pemilihan nilai K yang berbeda dapat menghasilkan komposisi keanggotaan cluster yang juga berbeda, sehingga berdampak pada hasil akhir pengelompokan (Jamal & Yanto, 2019). Untuk mengatasi permasalahan ini, diperlukan teknik optimasi, dan salah satu pendekatan yang paling sering digunakan adalah metode Elbow (Umargono dkk., 2019).

Metode Elbow digunakan untuk menentukan jumlah cluster optimal dengan cara mengamati titik pada grafik yang membentuk sudut menyerupai siku (elbow), yang menunjukkan perubahan signifikan dalam nilai kesalahan kuadrat (Sum of Squared Error/SSE) seiring bertambahnya jumlah cluster (Perdana dkk., 2022). SSE sendiri merupakan total dari selisih kuadrat antara titik-titik data dan pusat clusternya (centroid) dalam ruang Euclidean. Umumnya, semakin besar nilai K, maka SSE akan semakin kecil, namun pada titik tertentu penurunan SSE menjadi tidak signifikan, dan titik tersebut dianggap sebagai jumlah cluster yang optimal (Umargono dkk., 2019; Fahrudin & Rindiyan, 2024).

Menentukan jumlah cluster yang tepat sangat penting karena secara langsung memengaruhi kualitas hasil pengelompokan. Jika jumlah cluster terlalu sedikit, maka struktur data menjadi lebih mudah dianalisis, tetapi informasi penting berpotensi terabaikan. Sebaliknya, jika jumlah cluster terlalu banyak, maka akan ada peningkatan kesamaan dalam masing-masing cluster, namun struktur menyeluruh data bisa terpecah-pecah dan sulit dimaknai (Adiana dkk., 2018).

Penggunaan metode Elbow telah terbukti mampu memperbaiki keterbatasan metode partisi dalam hal penentuan nilai K, sehingga meningkatkan efektivitas clustering. Titik siku pada grafik SSE memberikan gambaran yang jelas tentang jumlah cluster yang memberikan keseimbangan terbaik antara kompleksitas model dan kesalahan pengelompokan (Alamsyah dkk., 2022; Fahrudin & Rindiyan, 2024; Perdana dkk., 2022). Adapun tahapan dalam penerapan metode ini telah dijelaskan secara sistematis dalam studi Tivano dkk. (2023).

1. Menentukan nilai awal cluster (k)
2. Meningkatkan nilai k secara bertahap Menaikkan nilai k secara bertahap hingga mencapai nilai maksimal k yang diinginkan.

3. Menghitung nilai SSE Pada setiap cluster k , tentukan nilai SSE. Berikut bentuk persamaan dalam menghitung nilai SSE (Gustriansyah dkk., 2020).

Keterangan :

k : Jumlah cluster

n : Jumlah data dalam setiap cluster

x_i : Titik data ke- i dalam cluster

c_j : Titik pusat (centroid) dari cluster ke- j

$\|x_i^{(j)} - c_j\|^2$: Jarak Euclidean kuadrat antara titik data ke- i dalam cluster ke- j dengan centroid c_j dari cluster j

4. Memplot kurva SSE sesuai dengan jumlah cluster k .
5. Menentukan nilai k optimal.

Tahapan ini dilakukan dengan mencari titik dimana penurunan SSE mulai melambat (membentuk "siku"). Titik ini disebut "elbow point". Pada titik tersebut menunjukkan nilai k yang optimal. Selain itu, pada titik ini, penambahan jumlah cluster tidak memberikan pengurangan SSE yang signifikan

2.8 Metode K-Means

Algoritma K-Means merupakan salah satu metode machine learning berbasis clustering non-hierarki yang dikenal karena kesederhanaan dan kemudahannya dalam penerapan, sehingga menjadikannya sangat populer di kalangan peneliti dan praktisi (Mirantika & Rijanto, 2023). Mekanisme algoritma ini melibatkan pembagian data ke dalam sejumlah K cluster dengan tujuan untuk meminimalkan jarak antara masing-masing data dalam cluster terhadap pusat cluster atau centroid, berdasarkan perhitungan jarak Euclidean (Fahrudin & Rindiyan, 2024; Syakur dkk., 2018). Jarak Euclidean sendiri digunakan untuk mengukur jarak antar titik data, sehingga memungkinkan pengelompokan berdasarkan kedekatan terhadap rata-rata pusat (Paembonan & Abduh, 2021).

Algoritma K-Means terdiri dari dua tahap utama yang berlangsung secara iteratif. Tahap pertama adalah proses inisialisasi atau penugasan, di mana setiap data ditetapkan ke centroid terdekat berdasarkan jarak Euclidean. Tahap kedua adalah pembaruan centroid, yang dilakukan dengan menghitung ulang posisi pusat cluster berdasarkan anggota data yang ada. Proses ini akan terus berlangsung

hingga tidak ada perubahan dalam keanggotaan cluster atau hingga jumlah iterasi maksimum tercapai (Oti dkk., 2021). Dalam implementasinya, terdapat dua prinsip dasar yang harus dipenuhi, yaitu data dalam satu cluster harus memiliki kemiripan yang tinggi, sementara data dari cluster yang berbeda harus memiliki perbedaan yang maksimal (Fahrudin & Rindiyan, 2024).

K-Means memiliki kelebihan terutama efisiensinya dalam menangani dataset berukuran besar (Sajidah dkk., 2023). Selain itu, algoritma ini dikenal karena kemudahan dalam implementasi, proses perhitungan yang cepat, dan fleksibilitas penggunaannya pada data numerik. Hasil clustering K-Means juga cenderung mudah dipahami dan diinterpretasikan (Murpratiwi dkk., 2021; Pradhan, 2021).

Tahapan implementasi algoritma K-Means telah dijelaskan secara sistematis oleh Tivano dkk. (2023), yang mencakup proses awal penentuan jumlah cluster hingga evaluasi hasil akhir clustering.

1. Menentukan jumlah cluster k yang akan dibentuk.
2. Menetapkan nilai k secara acak sebagai lokasi atau titik pusat cluster awal (centroid).
3. Tempatkan titik centroid dengan setiap titik data. Kedekatan titik centroid dengan titik data ditentukan berdasarkan jarak antara kedua objek tersebut, sehingga data akan dimasukkan ke dalam suatu cluster yang memiliki jarak paling dekat dengan titik pusat dari setiap cluster. Untuk menghitung jarak semua data ke setiap titik pusat cluster dapat menggunakan teori jarak Euclidean dengan persamaan seperti berikut.

$$D(i, j) = \sqrt{(X_{1i} - X_{1j})^2 + (X_{2i} - X_{2j})^2 + \dots + (X_{ki} - X_{kj})^2}$$

Keterangan :

$D(i, j)$: Jarak data ke- i ke pusat cluster j

X_{ki} : Nilai data ke- i pada atribut data ke- k

X_{kj} : Titik pusat ke- j pada atribut ke- k

4. Tempatkan semua titik data ke dalam cluster yang terdekat dengan menggunakan jarak yang didapatkan.

5. Mencari titik centroid atau pusat cluster yang baru berdasarkan jumlah jarak tiap data yang dibagi dengan jumlah titik data yang ada pada cluster tersebut dengan persamaan berikut.

$$C_i = \frac{1}{m} \sum_{j=1}^m X_j$$

Keterangan :

C_i : Titik centroid dari cluster ke-i

m : Banyaknya data dalam cluster

X_j : Titik data ke-j pada cluster

6. Setelah mendapatkan titik pusat yang baru dari setiap cluster, lakukan kembali perhitungan dari langkah 3. Jika titik centroid tidak berubah lagi dan tidak ada lagi data yang berpindah dari satu cluster ke cluster yang lain maka proses clustering selesai.

2.9 Evaluasi Model

Evaluasi performa model clustering dapat dilakukan dengan memanfaatkan dua metrik utama, yaitu *Silhouette Score* dan *Davies-Bouldin Index*. *Silhouette Score* merupakan salah satu metode evaluasi yang digunakan untuk menilai seberapa baik suatu titik data ditempatkan dalam cluster yang telah ditetapkan dibandingkan jika titik tersebut berada di cluster lain (Rousseeuw, 1987). Metrik ini menggabungkan dua konsep penting dalam evaluasi clustering, yaitu *cohesion*, yang mengukur seberapa dekat hubungan antar objek dalam satu cluster, dan *separation*, yang menilai seberapa jauh jarak antar objek dari cluster yang berbeda (Tivano dkk., 2023).

Nilai dari *Silhouette Score* berada dalam rentang -1 hingga 1. Skor mendekati 1 menunjukkan bahwa objek berada pada cluster yang tepat dan sangat berbeda dari cluster lain, sedangkan nilai mendekati -1 menunjukkan bahwa objek kemungkinan besar salah ditempatkan karena memiliki kemiripan lebih besar dengan cluster lain dibandingkan dengan cluster asalnya (Teslenko dkk., 2023). Dengan demikian, semakin tinggi nilai *Silhouette Score*, semakin baik kualitas pemisahan antar cluster dalam model.

Davies-Bouldin Index (DBI) merupakan salah satu metrik evaluasi yang digunakan untuk menilai kualitas hasil clustering dengan mengukur tingkat

pemisahan antar cluster serta kekompakan data di dalam masing-masing cluster. Metrik ini dirancang untuk memaksimalkan jarak antara cluster yang berbeda, sekaligus meminimalkan jarak antar data dalam satu cluster yang sama (Davies & Bouldin, 1979). Ketika jarak antar cluster besar, hal ini menunjukkan bahwa perbedaan karakteristik antar kelompok cukup signifikan, sehingga pemisahan antar cluster menjadi lebih jelas. Sebaliknya, jarak yang kecil di dalam satu cluster mengindikasikan bahwa objek-objek dalam kelompok tersebut memiliki kemiripan yang tinggi.

Tabel 2.1 Kriteria Keباikan Silhouette Score (Karo dkk., 2023)

Interval Silhouette Score	Deskripsi
0,71 - 1	Strong Cluster
0,51 - 0,7	Reasonable Cluster
0,26 - 0,5	Weak Cluster
< 0,25	Wrong Cluster

Nilai DBI berada pada rentang lebih besar atau sama dengan nol ($DBI \geq 0$), dan semakin kecil nilai indeks ini, maka semakin baik kualitas cluster yang terbentuk. Dengan kata lain, nilai DBI yang rendah menunjukkan bahwa cluster yang dihasilkan memiliki tingkat kekompakan yang tinggi dan keterpisahan yang jelas satu sama lain, sehingga mencerminkan struktur segmentasi yang optimal dalam data (Gustriansyah dkk., 2020).

Tabel 2.2 Kriteria Keباikan Davies Bouldin Index


DBI Value	Interpretasi Umum
≈ 0	Cluster sangat terpisah (ideal)
0.5 – 1.0	Cluster cukup baik, dengan pemisahan yang baik
≈ 1.0	Cluster kurang optimal, terjadi tumpang tindih antar cluster
> 1.0	Cluster buruk (tidak terpisah jelas)

BAB III

METODE PELAKSANAAN

3.1 Alur Kerja

Bagian ini menyajikan gambaran umum mengenai tahapan-tahapan yang akan dilalui dalam penelitian atau proyek ini. Alur kerja ini dirancang untuk memastikan proses analisis data dilakukan secara sistematis dan komprehensif, mulai dari persiapan data hingga penyusunan rekomendasi. Diagram di bawah ini mengilustrasikan setiap langkah yang akan diambil, menunjukkan interkoneksi antar tahapan, serta bagaimana setiap proses berkontribusi pada pencapaian tujuan akhir.



Gambar 3.1 Alur Kerja

3.2 Sumber Data

Data yang digunakan dalam penelitian ini diperoleh dari dataset asuransi yang berisi informasi mengenai pelanggan dan polis asuransi. Dataset ini bersumber dari sumber data asli, misal perusahaan asuransi, lembaga riset, atau dataset publik, dan berisi variabel-variabel terkait demografi pelanggan, produk asuransi yang dimiliki, riwayat klaim, serta preferensi komunikasi pelanggan. Data ini digunakan untuk melakukan analisis segmentasi pelanggan agar dapat membantu perusahaan dalam mengembangkan strategi pemasaran yang lebih efektif.

3.2.1 Deskripsi Dataset

Dataset asuransi ini terdiri dari sejumlah variabel yang mencakup berbagai aspek pelanggan dan polis yang dimiliki. Dataset akan dibagi menjadi tiga kategori berdasarkan informasi yang dimuat, sebagai berikut:

1. Demografi Pelanggan (*Customer Demographics*)

Data ini mencakup informasi dasar tentang karakteristik pribadi pelanggan yang berguna untuk mengelompokkan mereka berdasarkan profil demografis. Berikut merupakan penjelasan dari masing-masing variabel.

- Customer ID: Identifikasi unik pelanggan.
- Age: Usia pelanggan.
- Gender: Jenis kelamin pelanggan.
- Marital Status: Status pernikahan pelanggan.
- Occupation: Pekerjaan pelanggan.
- Income Level: Kategori pendapatan pelanggan.
- Education Level: Tingkat pendidikan pelanggan.
- Geographic Information: Wilayah tempat tinggal pelanggan.
- Location: Kota atau daerah pelanggan.

2. Perilaku Pelanggan (*Behavioral Data*)

Data ini menggambarkan perilaku dan interaksi pelanggan yang penting untuk analisis pola dan kebutuhan mereka. Berikut merupakan penjelasan dari masing-masing variabel.

- Behavioral Data: Pola perilaku pelanggan.
- Purchase History: Riwayat pembelian pelanggan.
- Interactions with Customer Service: Catatan interaksi dengan layanan pelanggan.
- Customer Preferences: Preferensi pelanggan.
- Life Events: Peristiwa hidup yang mempengaruhi kebutuhan asuransi.
- Previous Claims History: Riwayat klaim sebelumnya.
- Claim History: Riwayat klaim pelanggan.
- Credit Score: Skor kelayakan kredit pelanggan.
- Driving Record: Riwayat pelanggaran mengemudi.

3. Produk dan Polis Asuransi (*Insurance Policy Data*)

Data ini mencakup informasi mengenai produk asuransi dan detail polis yang dimiliki oleh pelanggan. Berikut merupakan penjelasan dari masing-masing variabel.

- Policy Start Date: Tanggal mulai polis.
 - Policy Renewal Date: Tanggal perpanjangan polis.
 - Insurance Products Owned: Produk asuransi yang dimiliki.
 - Coverage Amount: Jumlah pertanggungan.
 - Premium Amount: Premi yang dibayar.
 - Deductible: Biaya yang dibayar pelanggan sebelum klaim.
- Policy Type: Jenis polis asuransi.

4. Preferensi Komunikasi (*Communication Preferences*)

Data ini memuat cara dan waktu komunikasi yang disukai pelanggan untuk meningkatkan efektivitas interaksi.

Variabel:

- Preferred Communication Channel: Saluran komunikasi favorit.
- Preferred Contact Time: Waktu terbaik untuk menghubungi pelanggan.
- Preferred Language: Bahasa yang dipilih pelanggan.

3.3 Metode Penyelesaian Proyek

3.3.1 Data Understanding

Pada tahap ini, dataset pelanggan AXA Mandiri Jakarta dipelajari untuk memahami tipe data, struktur, serta variabel-variabel yang tersedia. Data berisi informasi demografi, perilaku, dan histori interaksi pelanggan dengan layanan asuransi, termasuk variabel penting seperti tanggal mulai dan perpanjangan polis, jumlah premi, serta interaksi dengan customer service. Pemahaman ini menjadi dasar untuk proses pembersihan dan pemilihan fitur yang relevan untuk segmentasi. Berikut merupakan langkah eksplorasi.

- Menampilkan sebagian data (head), informasi struktur data (info), dan ringkasan statistik.
- Identifikasi missing values dan tipe data pada setiap kolom.

3.3.2 Data Preprocessing

Pada tahap ini, data mentah yang diperoleh dari dataset pelanggan AXA Mandiri Jakarta dibersihkan dan disiapkan agar siap untuk dianalisis. Pada tahap ini, data mentah diproses agar siap untuk analisis. Langkah-langkah yang dilakukan meliputi sebagai berikut.

1. Identifikasi dan Penanganan Nilai Hilang (Missing Values)

Penanganan nilai yang hilang merupakan langkah penting dalam pra-pemrosesan data. Data kosong atau hilang dapat mengganggu kualitas analisis dan akurasi model. Oleh karena itu, penanganannya bisa dilakukan dengan dua pendekatan, yaitu menghapus baris yang mengandung nilai kosong jika jumlahnya sedikit, atau mengimputasi nilai tersebut menggunakan teknik tertentu seperti pengisian dengan nilai rata-rata, median, modus, atau metode prediktif lainnya sesuai dengan konteks dan kebutuhan analisis.

2. Pengecekan dan Penghapusan Data Duplikat

Tahapan ini bertujuan untuk menghindari bias dalam analisis data. Duplikasi data terjadi ketika satu atau lebih baris data muncul lebih dari sekali dalam dataset. Keberadaan data yang berulang ini dapat menyebabkan distorsi dalam hasil analisis statistik maupun pemodelan machine learning.

3. Konversi Format Tanggal

Tanggal pada atribut *Policy Renewal Date* yang masih berbentuk string harus dikonversi ke tipe data *datetime* agar dapat digunakan dalam operasi waktu seperti pengelompokan berdasarkan bulan dan perhitungan selisih hari.

4. Standarisasi Format Data

Standarisasi penting untuk memastikan data dapat dianalisis secara tepat dan mencegah error ketika dilakukan proses modeling atau visualisasi.

5. Transformasi Data Numerik dengan MinMaxScaler

Tahapan ini meliputi proses penskalaan ulang data numerik agar berada dalam rentang nilai tertentu, biasanya antara nol dan satu. Tahapan dari

metode Min-Max Scaler menggunakan rumus yang telah dijelaskan pada subbab 2.5.

6. Validasi Data

Proses ini merupakan tahap akhir dari proses pembersihan data, yang memastikan bahwa semua data telah sesuai dengan tipe dan rentang nilai yang diharapkan. Validasi ini penting untuk menjamin integritas dan keandalan data sebelum digunakan dalam analisis lebih lanjut.

3.3.3 *Exploratory Data Analysis*

Tahap EDA bertujuan untuk memahami karakteristik data pelanggan dan pola distribusi fitur RFM. Analisis deskriptif seperti mean, median, dan distribusi frekuensi dilakukan pada setiap variabel RFM. Visualisasi seperti histogram, boxplot, dan scatterplot digunakan untuk mengidentifikasi outlier, distribusi nilai, serta hubungan antar fitur. Visualisasi awal kluster juga dilakukan untuk memahami penyebaran pelanggan berdasarkan fitur RFM.

3.3.4 *Features Engineering*

Pada tahap ini, dilakukan perhitungan tiga fitur utama RFM seperti yang telah dijelaskan pada subbab 2.4. Data RFM dinormalisasi menggunakan StandardScaler agar seluruh fitur berada pada skala yang sama untuk meningkatkan performa algoritma clustering.

3.3.5 Penentuan Jumlah Cluster Optimal

Dalam *clustering* untuk mendapatkan *cluster* segmentasi optimal dapat ditentukan dengan jumlah cluster terbaik. Proses tersebut dapat menggunakan metode diantaranya sebagai berikut.

- Elbow Method

Metode ini dilakukan dengan mengamati grafik total within-cluster sum of squares (inertia) untuk menemukan titik “elbow”.

- KneeLocator

Metode ini digunakan untuk membantu menentukan secara otomatis titik elbow pada grafik inertia.

- Silhouette Score

Nilai ini digunakan untuk mengevaluasi seberapa baik pemisahan antar cluster yang dihasilkan.

3.3.6 Modeling

Metode clustering K-Means dipilih untuk mengelompokkan pelanggan berdasarkan fitur RFM. Penentuan jumlah cluster optimal dilakukan secara otomatis menggunakan metode Elbow yang dibantu algoritma KneeLocator, serta dievaluasi dengan Silhouette Score untuk mendapatkan jumlah cluster terbaik yang menghasilkan segmentasi yang stabil dan bermakna. Model K-Means dilatih menggunakan inisialisasi k-means++ untuk memastikan hasil clustering yang konsisten dan menghindari solusi lokal yang buruk.

3.3.7 Segmentasi Demografi

Setelah melakukan modeling dengan menggunakan metode RFM, proses dilanjutkan dengan segmentasi customer berdasarkan demografinya. Hal ini dilakukan untuk memperkaya penggalian wawasan dari data yang ada. Selain itu, pada tahap ini juga dilakukan dengan tujuan menggali informasi karakteristik karakter demografi dari cluster terhadap jenis asuransi yang diambil.

3.3.8 Evaluasi

Evaluasi hasil clustering dilakukan dengan metrik Silhouette Score dan *Davies-Bouldin Index* untuk mengukur kualitas segmentasi secara kuantitatif. Visualisasi cluster dan peta batas klaster memberikan gambaran visual struktur segmentasi. Hasil segmentasi selanjutnya diinterpretasikan secara bisnis untuk mendukung penyusunan strategi pemasaran yang lebih tepat sasaran.

3.3.9 Penyusunan Rekomendasi

Berdasarkan hasil segmentasi dan evaluasi model, disusun rekomendasi strategi pemasaran yang terarah serta pengembangan produk yang sesuai karakteristik tiap segmen pelanggan. Rekomendasi ini bertujuan untuk meningkatkan efektivitas komunikasi pemasaran, personalisasi penawaran, serta memperkuat kepuasan dan loyalitas pelanggan.

3.4 Kontrak Kerja

Terlampir

3.5 Rincian Harga

Terlampir

3.6 Linimasa Proyek

Berikut merupakan linimasa dari proyek yang telah disepakati.

Kegiatan	Mei 2025				Keterangan
	1	2	3	4	
Proposal					Phase 1
Document Review					
Bid Date					
Data Collection					Phase 2
Data Cleaning dan Preprocessing					
Feature Extraction					
Modelling					
Evaluasi Model					
Progress Report					
Improvement					Phase 3
Analisis Hasil Model					
Laporan					Phase 4

BAB IV

HASIL DAN PEMBAHASAN

4.1 Hasil Analisis Data

4.1.1 Data Understanding

Pada tahap awal, dilakukan pemahaman terhadap struktur dan isi dataset "Insurance Data" yang berjumlah 150.000 data pelanggan. Data tersebut memuat atribut demografi, perilaku, serta informasi polis dan klaim, antara lain: umur, gender, status pernikahan, pekerjaan, tingkat pendapatan, lokasi, preferensi, hingga riwayat interaksi dengan customer service dan histori klaim. Data yang digunakan telah di-drop kolom guna memfokuskan menggunakan variabel yang akan berpengaruh.

4.1.2 Data Preprocessing

a. Pengecekan Tipe Data dan Missing Value

Langkah pertama dalam preprocessing adalah melakukan identifikasi tipe data pada setiap kolom serta memeriksa adanya missing value. Dari hasil pengecekan menggunakan `data.info()`, diketahui bahwa dataset memiliki total 28 kolom dengan tipe data sebagai berikut:

- Integer (int64): Digunakan untuk data numerik diskrit seperti umur (Age), jumlah interaksi (Interactions with Customer Service), jumlah klaim sebelumnya (Previous Claims History), skor kredit (Credit Score), coverage amount (Coverage Amount), dan lain-lain.
- Float (float64): Digunakan untuk nilai numerik kontinu seperti jumlah premi (Premium Amount) dan deductible (Deductible).
- Object: Tipe data kategorik seperti Gender, Marital Status, Occupation, Education Level, Income Level, Location, Behavioral Data, dan sebagainya.
- Datetime: Terdapat pada kolom Policy Start Date dan Policy Renewal Date, yang berisi informasi tanggal.

Setelah identifikasi tipe data, dilakukan pengecekan missing value

- Kolom dengan missing value (berisi nilai kosong/null) antara lain:

1. Income Level (7.500 missing)
 2. Education Level (7.500 missing)
 3. Behavioral Data (7.500 missing)
 4. Claim History (7.500 missing)
 5. Risk Profile (7.500 missing)
- Kolom numerik seperti Premium Amount dan Deductible tidak ditemukan missing value.
 - Kolom bertipe tanggal (Policy Start Date, Policy Renewal Date) tidak memiliki missing value.

b. Penanganan Missing Value

Agar data dapat diproses dengan baik pada tahap berikutnya, seluruh missing value harus ditangani. Proses penanganan missing value dilakukan berdasarkan tipe data sebagai berikut.

1. Kolom Kategorik (object)

Untuk setiap kolom bertipe kategorik yang memiliki missing value, dilakukan pengisian (imputasi) menggunakan modus (nilai yang paling sering muncul pada kolom tersebut). Sebagai contoh jika pada kolom Income Level terdapat missing value, maka nilai kosong tersebut akan diisi dengan kategori yang paling sering muncul, misalnya "Medium".

2. Kolom Numerik (integer/float)

Untuk setiap kolom bertipe numerik yang memiliki missing value, dilakukan pengisian dengan rata-rata (mean) dari kolom tersebut. Sebagai contoh jika terdapat kolom numerik lain yang memiliki missing value, nilai kosong tersebut akan diisi dengan nilai rata-rata dari seluruh isi kolom.

3. Kolom Datetime

Pada dataset ini, kolom bertipe tanggal tidak ditemukan missing value sehingga tidak diperlukan imputasi khusus.

Setelah seluruh proses imputasi selesai dilakukan, dilakukan pengecekan ulang dengan `data.isnull().sum()`. Hasilnya menunjukkan bahwa seluruh


missing value telah berhasil diatasi, sehingga data sudah siap untuk proses analisis selanjutnya.

c. Transformasi Data dengan MinMaxScaler

Setelah proses penanganan missing value, tahap selanjutnya adalah melakukan transformasi data numerik menggunakan teknik MinMaxScaler. Tujuannya adalah untuk memastikan seluruh fitur numerik berada pada rentang skala yang sama (biasanya antara 0 dan 1), sehingga tidak ada fitur yang mendominasi proses clustering karena skala nilainya yang lebih besar. Kolom-kolom numerik seperti Age, Coverage Amount, Premium Amount, Deductible, Recency, Frequency, dan Monetary akan dilakukan normalisasi. Transformasi ini memastikan bahwa setiap kolom numerik akan berada pada rentang 0 sampai 1.

4.1.3 Exploratory Data Analysis (EDA)

a. Variabel Interaction with Customer Service




Gambar 4.1 Histogram Variabel Interaction with Customer Service

Pada sumbu x terdapat nilai interaksi yang berkisar antara 0 hingga 17,5, sedangkan sumbu y menunjukkan frekuensi dari masing-masing nilai tersebut. Histogram menunjukkan bahwa distribusi interaksi dengan layanan pelanggan sangat merata di seluruh rentang nilai. Setiap bin pada histogram memiliki frekuensi yang hampir seragam, umumnya berada di kisaran 7.400 hingga 7.800. Tidak terlihat adanya lonjakan atau penurunan signifikan, baik pada nilai interaksi rendah maupun tinggi. Hal ini mengindikasikan bahwa aktivitas pelanggan dalam

menghubungi layanan pelanggan berlangsung secara konsisten, tanpa kecenderungan hanya terjadi pada kelompok tertentu saja. Distribusi yang datar ini juga mendukung bahwa tidak ada segmentasi ekstrem berdasarkan tingkat interaksi dengan customer service.


b. Variabel Previous Claims History



Gambar 4.2 Histogram Variabel Previous Claims History

Pada sumbu x terdapat nilai dari 0 hingga 4, yang mewakili kategori sejarah klaim, sementara sumbu y menunjukkan frekuensi masing-masing kategori klaim. Dari histogram ini, terlihat bahwa kelima kategori (0, 1, 2, 3, dan 4) memiliki frekuensi yang hampir sama, yaitu sekitar 30.000. Tidak terdapat lonjakan atau penurunan yang signifikan antar kategori. Hal ini mengindikasikan bahwa distribusi jumlah klaim pelanggan bersifat seimbang, dengan tidak adanya dominasi atau kecenderungan tertentu terhadap nilai klaim rendah maupun tinggi. Dengan kata lain, pelanggan dengan riwayat klaim sedikit maupun banyak memiliki proporsi yang relatif sama dalam dataset ini, sehingga tidak terlihat pola segmentasi klaim yang menonjol.


c. Variabel Coverage Amount



Gambar 4.3 Histogram Variabel Coverage Amount

Pada sumbu x ditampilkan nilai Coverage Amount yang berkisar antara 0 hingga 1.000.000, sedangkan sumbu y menunjukkan frekuensi kemunculan nilai tersebut. Berdasarkan histogram, distribusi data tampak cukup merata di seluruh rentang nilai cakupan, dengan frekuensi yang stabil di sekitar 5.000 untuk hampir seluruh rentang. Terdapat sedikit fluktuasi kecil antar bin, namun tidak signifikan. Frekuensi sedikit menurun di bagian ujung kiri dan kanan (nilai ekstrem rendah dan tinggi), tetapi secara keseluruhan data Coverage Amount tersebar konsisten di berbagai level. Hal ini menunjukkan bahwa nasabah asuransi memiliki jumlah pertanggungan yang beragam, tanpa kecenderungan kuat terhadap cakupan rendah maupun tinggi.


d. Variabel Premium Amount



Gambar 4.4 Histogram Variabel Premium Amount

Pada sumbu x, nilai premi berkisar antara 0 hingga 5000, sementara pada sumbu y menunjukkan frekuensi dari masing-masing nilai premi. Dari histogram ini, terlihat bahwa distribusi frekuensi relatif merata di seluruh rentang nilai premi, dengan sedikit fluktuasi pada nilai yang lebih rendah (dekat 0). Nilai premi yang lebih rendah tampaknya memiliki frekuensi yang sedikit lebih tinggi dibandingkan dengan nilai premi yang lebih tinggi, namun secara keseluruhan distribusi menunjukkan pola yang cukup konsisten. Penurunan frekuensi pada ujung kanan menunjukkan bahwa semakin tinggi jumlah premi, semakin sedikit frekuensinya.

e. Heatmap Correlation



Gambar 4.5 Heatmap Correlation

Heatmap yang ditampilkan menunjukkan korelasi antara berbagai variabel. Nilai-nilai korelasi berkisar antara -1 hingga 1, yang mengindikasikan kekuatan dan arah hubungan antara dua variabel. Dari heatmap ini, dapat dilihat bahwa hampir semua variabel memiliki korelasi yang sangat rendah, dengan sebagian besar nilai korelasi mendekati 0, menunjukkan hubungan yang lemah antar variabel. Misalnya, korelasi antara "Usia" dan "Interaksi dengan Layanan Pelanggan" adalah -0.00295, yang menunjukkan hampir tidak ada

hubungan sama sekali antara kedua variabel tersebut. Korelasi yang lebih tinggi ditemukan antara variabel "Interaksi dengan Layanan Pelanggan" dan "Jumlah Cakupan" yang memiliki nilai 0.00667, namun ini juga tergolong sangat lemah. Secara keseluruhan, heatmap ini menunjukkan bahwa variabel-variabel yang ada dalam data ini tidak memiliki hubungan yang signifikan satu sama lain.

4.1.4 Feature Engineering

Pada tahap ini, dilakukan proses rekayasa fitur (feature engineering) untuk mengubah data mentah menjadi atribut-atribut baru yang lebih bermakna dan relevan untuk segmentasi pelanggan menggunakan pendekatan RFM (Recency, Frequency, Monetary). Adapun langkah dan penjelasan detailnya sebagai berikut:

a. Recency

Recency didefinisikan sebagai jarak waktu (dalam hari) antara tanggal acuan analisis dengan tanggal perpanjangan polis terakhir setiap pelanggan. Semakin kecil nilai recency, semakin baru pelanggan melakukan aktivitas perpanjangan polis. Berdasarkan subbab 2.4, recency memiliki rumus $\text{recency} = (\text{reference_date} - \text{Policy Renewal Date}) \text{ days}$ dengan tanggal acuan (reference_date) adalah 25 Mei 2025 (2025-05-25). Sebagai contoh jika seorang pelanggan terakhir memperpanjang polis pada 10 Mei 2025, maka nilai recency-nya adalah 15 hari.

b. Frequency

Frequency menggambarkan seberapa sering pelanggan melakukan aktivitas tertentu yang relevan dengan asuransi. Dalam pelaksanaan proyek ini, frequency tidak hanya satu macam, tetapi dikombinasikan dari beberapa atribut, diantaranya sebagai berikut.

- Lama waktu menjadi nasabah: $\text{Policy Renewal Date} - \text{Policy Start Date}$
- Previous Claims History: Jumlah klaim yang pernah diajukan pelanggan sebelumnya.

c. Monetary

Monetary adalah indikator nilai finansial dari pelanggan untuk perusahaan asuransi, yang dihitung dengan beberapa cara. Dalam

pelaksanaan proyek ini menggunakan Premium Amount (Total premi yang dibayarkan pelanggan).

d. Kombinasi Fitur RFM

Untuk mengeksplorasi segmentasi dari berbagai sudut pandang, dilakukan 4 kombinasi berbeda dari fitur RFM. Setiap kombinasi dirancang untuk bisa memberikan wawasan unik terhadap perilaku dan nilai pelanggan. Kombinasi tersebut adalah sebagai berikut.

- Kombinasi 1
 - Recency: Selisih hari sejak perpanjangan polis terakhir.
 - Frequency: lama customer menjadi nasabah
 - Monetary: Total premi yang dibayarkan pelanggan.
 - Tujuan: Mengidentifikasi pelanggan yang sering berinteraksi dan memberikan kontribusi finansial lewat pembayaran premi.
- Kombinasi 2
 - Recency: Selisih hari sejak perpanjangan polis terakhir.
 - Frequency: Hanya riwayat klaim (Previous Claims History).
 - Monetary: Premi.
 - Tujuan: Fokus pada pelanggan yang aktif mengajukan klaim, untuk analisis risiko dan perilaku klaim.

4.1.5 Penentuan Jumlah Cluster Optimal

Pada tahap ini dilakukan proses untuk menentukan jumlah cluster (k) yang paling optimal sebelum melakukan modeling clustering dengan algoritma K-Means. Jumlah cluster optimal dipilih berdasarkan metode Elbow dan didukung dengan KneeLocator yang secara otomatis mendeteksi titik “tekuk” (elbow) pada grafik inertia.

a. Proses Penentuan k

- Untuk setiap kombinasi fitur RFM, dilakukan training KMeans dengan variasi jumlah cluster, mulai dari $k = 2$ hingga $k = 10$.
- Setiap nilai k dihitung nilai inertia-nya (total jarak kuadrat dari setiap data ke pusat clusternya).
- Nilai inertia diplotkan terhadap jumlah cluster untuk membentuk grafik Elbow.

- Dengan bantuan Knee Locator, titik tekuk pada kurva dapat dideteksi secara otomatis sebagai kandidat jumlah cluster optimal.

b. Hasil Penentuan Jumlah Cluster

- Didapatkan $k=4$ pada kombinasi 1 dan juga mendapatkan k optimal $k=3$ pada kombinasi 2.
- Nilai k yang didapatkan dari Elbow/KneeLocator tidak harus selalu sama untuk setiap kombinasi atau setiap eksperimen.

4.1.6 Modeling dan Clustering

Untuk memastikan kualitas hasil segmentasi pelanggan yang dihasilkan dari model K-Means, dilakukan evaluasi menggunakan Silhouette Score pada setiap kombinasi fitur RFM yang diuji. Nilai Silhouette Score ini digunakan sebagai indikator objektif untuk menilai seberapa baik pemisahan antar cluster pada setiap skenario segmentasi.

Tabel 4.1.6 Hasil Evaluasi Model RFM Pada Setiap Kombinasi

Kombinasi	Jumlah Cluster (k)	DBI	Silhouette Score
Kombinasi 1	4	1,1698	0.2752
Kombinasi 2	3	1,3504	0.2643

Berdasarkan Tabel 4.1.6 dapat diinterpretasikan untuk masing masing kombinasi seperti berikut.

- Kombinasi 1

$K=4$, Silhouette Score: 0,2752, DBI: 1,1698

Hasil evaluasi clustering dengan $K=4$ pada Kombinasi 1 menunjukkan bahwa kualitas segmentasi pelanggan masih belum optimal. Nilai Silhouette Score sebesar 0,2752 termasuk ke dalam kategori weak cluster, yang mengindikasikan bahwa pemisahan antar kelompok pelanggan masih lemah. Selain itu, nilai Davies Bouldin Index sebesar 1,1698 juga tergolong kurang baik karena menunjukkan adanya tumpang tindih antar cluster. Secara keseluruhan, struktur segmentasi pada Kombinasi 1 masih belum cukup jelas, sehingga pemanfaatan hasil clustering perlu dilakukan dengan kehati-hatian, serta disertai dengan evaluasi dan monitoring secara berkala untuk meningkatkan efektivitas strategi bisnis ke depannya.

- **Kombinasi 2**

K=3, Silhouette Score: 0.2643, DBI: 1,3504


Pada Kombinasi 2 dengan K=3, hasil evaluasi juga memperlihatkan bahwa segmentasi yang terbentuk belum optimal. Nilai Silhouette Score sebesar 0,2653 masih berada pada rentang weak cluster, yang berarti pemisahan antar cluster kurang tegas dan potensi overlap antar kelompok pelanggan masih cukup tinggi. Sementara itu, nilai DBI sebesar 1,3504 juga tergolong kurang baik, menunjukkan tingkat tumpang tindih yang signifikan antar cluster. Dengan demikian, segmentasi pelanggan yang dihasilkan pada Kombinasi 2 sebaiknya juga digunakan secara hati-hati dan terus dimonitor, agar strategi bisnis yang diterapkan dapat lebih tepat sasaran dan efektif.

Secara umum, nilai Silhouette Score pada kedua kombinasi berada pada kisaran 0,26–0,27 yang termasuk dalam kategori weak cluster (lemah). Begitu pula dengan nilai DBI pada kisaran 1,16–1,35, yang menunjukkan adanya tumpang tindih antar cluster. Hal ini berarti, meskipun segmentasi yang terbentuk sudah dapat memberikan insight terkait perilaku pelanggan, struktur pemisahan antar kelompok masih belum optimal.

4.2 Pembahasan

Pada tahap ini, dilakukan interpretasi hasil segmentasi pelanggan berdasarkan dua kombinasi fitur RFM yang telah dihasilkan melalui proses clustering. Setiap kombinasi menawarkan perspektif yang berbeda dalam memahami loyalitas, nilai finansial, dan risiko dari pelanggan AXA Mandiri Jakarta.

4.2.1 Kombinasi 1



Gambar 4.2.1 Cluster Kombinasi 1

Pada bagian ini dilakukan interpretasi hasil segmentasi pelanggan berdasarkan kombinasi fitur RFM pertama, yaitu Recency, Frequency, dan Monetary dengan definisi variabel sebagai berikut:

- **Recency** dihitung sebagai selisih hari antara tanggal acuan penelitian (25 Mei 2025) dan tanggal perpanjangan polis terakhir. Semakin kecil nilai recency, semakin baru pelanggan melakukan perpanjangan polis.
- **Frequency** diukur dari umur kepemilikan polis, yaitu selisih antara tanggal perpanjangan polis dan tanggal mulai polis, yang merepresentasikan durasi hubungan pelanggan dengan perusahaan.


- **Monetary** merepresentasikan total premi yang dibayarkan oleh pelanggan (Premium Amount), sebagai indikator kontribusi finansial terhadap perusahaan.

Pada kombinasi ini, segmentasi didasarkan pada kapan terakhir pelanggan memperpanjang polis, seberapa sering mereka berinteraksi dengan layanan pelanggan, serta besaran premi yang dibayarkan. Berikut merupakan karakteristik dari masing masing cluster

- **Cluster 0 (Biru):** Kelompok ini terdiri dari pelanggan yang sudah lama menjadi nasabah (frequency tinggi), baru-baru ini memperpanjang polis (recency rendah), dan memiliki premi tinggi. Mereka adalah pelanggan yang menunjukkan loyalitas jangka panjang sekaligus keterlibatan aktif dalam memperpanjang perlindungan mereka. Dengan nilai premi yang besar, pelanggan ini menjadi kontributor penting terhadap pendapatan perusahaan. Strategi: Fokus pada retensi jangka panjang, pemberian loyalty rewards, serta program eksklusif dan upselling produk tambahan.
- **Cluster 1 (Oranye):** Pelanggan dalam kelompok ini baru saja memperpanjang polis (recency rendah), namun baru bergabung (frequency rendah) dan membayar premi dalam jumlah sedang. Mereka merupakan nasabah baru yang sudah menunjukkan minat awal yang baik. Meskipun kontribusi saat ini belum besar, mereka menyimpan potensi jangka panjang jika dikelola dengan baik. Strategi: Onboarding intensif, edukasi produk asuransi, dan ajakan untuk memperluas perlindungan serta memperbarui secara rutin.
- **Cluster 2 (Hijau):** Kelompok ini terdiri dari pelanggan yang sudah lama menjadi nasabah (frequency tinggi) dan memiliki premi yang cukup tinggi, namun tidak lagi aktif dalam memperpanjang polis (recency tinggi). Artinya, mereka dulunya loyal tetapi kini mulai menunjukkan gejala pasif atau potensi churn. Strategi: Lakukan program reaktivasi, kirim reminder renewal, dan tawarkan insentif atau diskon untuk memperbarui kembali polis mereka.

- **Cluster 3 (Merah):** Cluster ini mencakup pelanggan yang memiliki masa keanggotaan pendek (frequency rendah), sudah lama tidak memperpanjang polis (recency tinggi), dan membayar premi dalam jumlah rendah. Mereka tergolong pelanggan yang tidak terlalu aktif maupun bernilai tinggi bagi perusahaan. Strategi: Lakukan promosi selektif, survei kebutuhan, dan evaluasi apakah mereka perlu diprioritaskan dalam strategi pemasaran atau tidak.

4.2.2 Kombinasi 2



Pada bagian ini dilakukan interpretasi hasil segmentasi pelanggan berdasarkan kombinasi fitur RFM kedua, yaitu Recency, Frequency, dan Monetary dengan definisi variabel sebagai berikut:

- **Recency** dihitung sebagai selisih hari antara tanggal acuan penelitian (25 Mei 2025) dan tanggal perpanjangan polis terakhir. Semakin kecil nilai recency, semakin baru pelanggan melakukan perpanjangan polis.
- **Frequency** diukur dari jumlah klaim yang pernah diajukan pelanggan (Previous Claims History), yang mencerminkan tingkat penggunaan layanan asuransi.
- **Monetary** merepresentasikan total premi yang dibayarkan oleh pelanggan (Premium Amount), sebagai indikator kontribusi finansial terhadap perusahaan.

Segmentasi ini difokuskan pada perilaku klaim dan kontribusi finansial, sehingga sangat relevan untuk keperluan manajemen risiko dan pengelolaan efisiensi portofolio asuransi. Berikut merupakan karakteristik dari masing masing cluster

- **Cluster 0 (Biru):** Pelanggan dengan jumlah klaim tinggi dan premi bervariasi. Mereka merupakan pelanggan dengan aktivitas klaim yang intensif. Strategi: Review profil risiko, edukasi mitigasi risiko, dan penyesuaian premi untuk menjaga profitabilitas.
- **Cluster 1 (Oranye):** Pelanggan yang pernah melakukan klaim 1–2 kali dengan nilai premi bervariasi. Mereka adalah pengguna layanan yang moderat dan masih memiliki potensi untuk berkembang. Strategi: Penguatan komunikasi, edukasi manfaat produk, dan monitoring perilaku klaim ke depan.
- **Cluster 2 (Hijau):** Pelanggan yang belum pernah mengajukan klaim, dengan kontribusi premi yang bervariasi. Kelompok ini relatif aman secara risiko dan menguntungkan bagi perusahaan. Strategi: Pemberian penghargaan loyalitas, promosi retensi, dan pelibatan dalam program engagement.

4.3 Segmentasi Demografi

Pada tahap ini akan dilakukan analisis dengan melakukan segmentasi pelanggan dengan menggunakan data demografi seperti Age, Gender, Marital Status, Occupation, Income Level, Education Level, dan Geographic Information. Metode yang digunakan adalah *clustering* dengan menggunakan K-Means. Untuk memperluas eksplorasi *insight*, pada tahap ini selain menggunakan data demografi juga menggunakan variabel seperti Insurance Products Owned dan Risk Profile. Berikut merupakan jumlah cluster dan evaluasi yang didapatkan.

Tabel 4.3 Hasil Evaluasi Model Segmentasi Berdasarkan Demografi

Jumlah Cluster (k)	DBI	Silhouette Score
3	2,395	0,116

Berdasarkan Tabel 4.3, hasil evaluasi clustering dengan K=3 pada model segmentasi dengan data demografi menunjukkan bahwa kualitas segmentasi pelanggan masih belum optimal. Nilai Silhouette Score sebesar 0,116 termasuk ke dalam kategori *wrong cluster*, yang mengindikasikan bahwa pemisahan antar kelompok pelanggan masih sangat lemah. Selain itu, nilai Davies Bouldin Index sebesar 2,395 juga tergolong sangat tidak baik karena menunjukkan adanya tumpang tindih antar cluster. Secara keseluruhan, struktur segmentasi pada model belum jelas, sehingga pemanfaatan hasil clustering perlu dilakukan dengan kehati-hatian, serta disertai dengan evaluasi dan monitoring secara berkala untuk meningkatkan efektivitas strategi bisnis ke depannya.

Dalam cluster nol memiliki rerata usia sebesar 48.57 tahun, dengan usia kebanyakan berada pada 69 tahun. Rentang usia dalam cluster ini berkisar antara 18 hingga 79 tahun. Mayoritas anggota cluster ini berjenis kelamin laki-laki, berstatus menikah, dan bekerja sebagai pensiunan (Retired). Tingkat pendapatan yang paling dominan adalah Medium, dengan tingkat pendidikan terbanyak yaitu Bachelor. Secara geografis, sebagian besar tinggal di wilayah Urban, memiliki produk asuransi jenis Home, dan memiliki profil risiko rendah (Low).

Kemudian pada cluster satu rata-rata usia berada pada 48.25 tahun, dengan mayoritas usia 31 tahun. Usia anggotanya juga bervariasi antara 18 hingga 79 tahun. Sebagian besar anggota cluster ini adalah laki-laki, dengan status

pernikahan janda/duda (Widowed), dan juga banyak yang telah pensiun (Retired). Tingkat pendapatan yang umum adalah Medium, serta tingkat pendidikan terbanyak adalah Bachelor. Lokasi geografis paling dominan adalah Rural, dengan produk asuransi yang paling umum adalah Multiple, dan profil risiko yang paling sering muncul adalah Low.

Adapun pada cluster kedua memiliki rata-rata usia 48.42 tahun, dengan mayoritas berada pada usia 26 tahun. Sama seperti cluster lainnya, rentang usia berada antara 18 hingga 79 tahun. Sebagian besar anggota cluster ini adalah perempuan, berstatus menikah, dan bekerja sebagai Engineer. Tingkat pendapatan dominan adalah Medium, dengan tingkat pendidikan terbanyak yaitu Master. Wilayah tempat tinggal yang paling umum adalah Urban, produk asuransi yang paling banyak dimiliki adalah Travel, dan mayoritas memiliki profil risiko rendah (Low).

4.4 Rekomendasi Strategis untuk Perusahaan

Berdasarkan hasil segmentasi pelanggan menggunakan dua kombinasi fitur RFM, berikut rekomendasi strategis yang dapat diimplementasikan oleh PT. AXA Mandiri Jakarta untuk meningkatkan kinerja pemasaran, pelayanan, dan pengelolaan risiko:

1. Pertahankan dan Tingkatkan Loyalitas Pelanggan Bernilai Tinggi

Fokuskan perhatian pada pelanggan yang tergabung dalam Cluster 0 (Kombinasi 1), yaitu pelanggan dengan loyalitas tinggi, umur polis panjang, pembaruan polis yang aktif (recency rendah), dan kontribusi premi besar.

Strategi:

- Tawarkan program loyalitas dan layanan eksklusif seperti VIP membership, cashback, atau reward points.
- Bangun komunikasi personal dan konsultatif secara berkala, misalnya dengan memberikan ucapan ulang tahun atau anniversary polis.
- Berikan penawaran produk tambahan (cross-sell/upsell) sesuai kebutuhan nasabah.

2. Optimalkan Pelanggan Baru dan Potensial

Pelanggan di Cluster 1 (Kombinasi 1) merupakan nasabah baru yang baru saja memperpanjang polis, namun kontribusi premi masih sedang.

Strategi:

- Sediakan onboarding digital dan edukasi produk secara bertahap
- Dorong engagement dengan promosi edukatif, reminder renewal, dan upselling

3. Reaktivasi Pelanggan Lama yang Mulai Tidak Aktif

Cluster 2 (Kombinasi 1) menunjukkan gejala churn: pelanggan lama, premi tinggi, namun tidak aktif memperpanjang.

Strategi:

- Kirim reminder, diskon renewal, atau campaign reaktivasi
- Lakukan survei kebutuhan agar dapat menyesuaikan ulang penawaran

4. Evaluasi Prioritas Pelanggan Kontribusi Rendah

Cluster 3 (Kombinasi 1) mencerminkan pelanggan yang pasif, berumur pendek, dan premi rendah.

Strategi:

- Lakukan evaluasi cost-to-serve
- Jika perlu, redirection ke produk mikro atau kampanye literasi asuransi ringan

5. Kelola Risiko Pelanggan Aktif Mengklaim

Cluster 0 (Kombinasi 2) berisi pelanggan dengan riwayat klaim tinggi dan premi variatif.

Strategi:

- Tinjau ulang profil risiko
- Sediakan program edukasi mitigasi risiko
- Terapkan penyesuaian premi berbasis perilaku klaim

6. Kembangkan Segmen Pengguna Moderat

Cluster 1 (Kombinasi 2) mencerminkan pengguna layanan sedang (1–2 klaim), dengan potensi pertumbuhan.

Strategi:

- Jalin komunikasi edukatif dan penawaran lanjutan

- Bangun kepercayaan untuk retensi dan peningkatan produk
7. Pertahankan Pelanggan Rendah Risiko
- Cluster 2 (Kombinasi 2) adalah pelanggan tanpa klaim, dengan premi stabil. Mereka menguntungkan dan loyal.
- Strategi:
- Berikan penghargaan loyalitas (misalnya bonus no-claim)
 - Luncurkan program referensi pelanggan atau upgrade perlindungan
8. Evaluasi Segmentasi Secara Berkala
- Perbarui segmentasi minimal setiap kuartal atau saat terjadi pergeseran signifikan dalam perilaku pelanggan
 - Gunakan hasil segmentasi ini sebagai landasan dinamis dalam CRM dan strategi digital marketing

Selain rekomendasi yang dihasilkan dari analisis RFM, terdapat juga rekomendasi yang dihasilkan dari segmentasi berdasarkan demografi. Berikut merupakan rekomendasi yang mungkin dapat diterapkan. Hasil clustering demografis memberikan gambaran yang jelas mengenai segmentasi demografis pelanggan berdasarkan usia, pekerjaan, tingkat pendidikan, pendapatan, dan perilaku dalam kepemilikan asuransi. Cluster 0, misalnya, didominasi oleh individu berusia menengah hingga lanjut, sebagian besar adalah pria yang sudah menikah dan telah pensiun, tinggal di wilayah urban, serta lebih cenderung memiliki produk asuransi rumah dan profil risiko rendah. Segmentasi ini menunjukkan bahwa mereka berpotensi tertarik pada produk perlindungan properti, asuransi kesehatan untuk usia lanjut, atau layanan keuangan pasca-pensiun. Promosi yang bersifat edukatif dan menekankan perlindungan jangka panjang akan lebih relevan untuk cluster ini.

Sementara itu, Cluster 1 menunjukkan ciri khas kelompok dengan komposisi yang serupa dalam hal usia, namun dengan lebih banyak individu berstatus janda/duda, tinggal di wilayah rural, dan memiliki lebih dari satu produk asuransi (multiple). Ini menandakan adanya ketertarikan terhadap diversifikasi perlindungan, sehingga strategi penawaran bundling produk asuransi atau penyesuaian premi berdasarkan risiko rendah dapat menjadi pendekatan yang

tepat. Informasi ini juga berguna bagi perencanaan program loyalitas atau insentif untuk mempertahankan konsumen multi-produk di segmen ini.

Adapun Cluster 2 terdiri dari perempuan yang sudah menikah, mayoritas bekerja sebagai Engineer dengan latar pendidikan tingkat Master, tinggal di wilayah urban, dan lebih banyak memiliki asuransi perjalanan (Travel). Ini menunjukkan profil konsumen yang aktif, berpendidikan tinggi, dan memiliki gaya hidup dinamis. Promosi produk yang bersifat fleksibel dan mendukung mobilitas seperti asuransi perjalanan, digital insurance, atau fitur premi yang bisa disesuaikan sehingga lebih cocok ditawarkan kepada segmen ini. Selain itu, mereka dapat menjadi target ideal untuk program referral atau inovasi layanan berbasis teknologi.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Proyek ini berhasil menerapkan metode segmentasi pelanggan berbasis pendekatan RFM (Recency, Frequency, Monetary) terhadap data nasabah AXA Mandiri Jakarta. Melalui serangkaian proses analisis yang mencakup pembersihan data, rekayasa fitur, eksplorasi variabel, pemodelan clustering menggunakan algoritma K-Means, serta evaluasi dengan metrik Silhouette Score, diperoleh dua kombinasi fitur yang memberikan perspektif strategis berbeda dalam memahami perilaku dan karakteristik pelanggan.

Kombinasi pertama menggunakan Recency sebagai jarak waktu sejak perpanjangan terakhir, Frequency sebagai umur polis (durasi kepemilikan), dan Monetary sebagai total premi yang dibayarkan. Segmentasi ini memberikan wawasan terkait loyalitas dan kontribusi finansial pelanggan. Dari hasil clustering, ditemukan empat kelompok pelanggan dengan karakteristik yang beragam—mulai dari pelanggan loyal bernilai tinggi hingga pelanggan dengan kontribusi rendah yang berisiko churn. Kombinasi ini terbukti efektif dalam mengarahkan strategi retensi, upselling, dan program loyalitas berbasis perilaku nyata pelanggan.

Sementara itu, kombinasi kedua menggunakan Recency yang sama, namun Frequency didefinisikan sebagai jumlah klaim sebelumnya, yang mencerminkan tingkat penggunaan layanan asuransi, dengan Monetary tetap berupa total premi. Hasil segmentasi menghasilkan tiga kelompok pelanggan, yang memetakan nasabah dari yang paling aktif melakukan klaim hingga mereka yang tidak pernah mengajukan klaim sama sekali. Kombinasi ini sangat relevan untuk mendukung strategi mitigasi risiko, efisiensi portofolio, serta penyesuaian premi dan edukasi perilaku klaim.

Meskipun hasil evaluasi clustering melalui nilai Silhouette Score masih berada dalam kategori weak clustering, segmentasi yang dihasilkan tetap memberikan informasi yang bernilai secara praktis. Distribusi cluster menunjukkan pola yang logis dan mampu menjadi dasar awal bagi strategi

pemasaran dan pengelolaan pelanggan yang lebih terarah. Dengan demikian, proyek ini membuktikan bahwa pendekatan segmentasi berbasis data dapat digunakan untuk mendukung pengambilan keputusan yang lebih tepat sasaran di sektor asuransi.

5.2 Saran

1. Integrasikan hasil segmentasi ke dalam sistem operasional perusahaan, khususnya pada Customer Relationship Management (CRM) dan strategi pemasaran digital, agar pendekatan terhadap pelanggan dapat dilakukan secara lebih personal dan berbasis data.
2. Prioritaskan retensi terhadap pelanggan loyal dan bernilai tinggi, khususnya yang termasuk dalam cluster dengan premi besar dan umur polis panjang. Tawarkan program loyalitas, benefit eksklusif, dan layanan premium untuk mempertahankan mereka.
3. Tingkatkan edukasi dan komunikasi terhadap pelanggan baru, terutama mereka yang baru memperpanjang polis namun belum menunjukkan keterlibatan yang tinggi. Strategi onboarding dan pemahaman produk perlu diperkuat agar mereka berkembang menjadi pelanggan aktif.
4. Lakukan monitoring dan edukasi risiko terhadap pelanggan dengan klaim tinggi, berdasarkan hasil segmentasi dari kombinasi kedua. Penyesuaian premi dan edukasi terkait mitigasi risiko asuransi dapat menekan potensi kerugian perusahaan.
5. Aktifkan kembali pelanggan lama yang tidak aktif, dengan cara mengirimkan kampanye reaktivasi yang berisi penawaran personal, reminder perpanjangan, atau potongan premi agar mereka kembali aktif sebagai nasabah.
6. Evaluasi ulang segmentasi secara berkala, terutama jika terjadi perubahan perilaku pelanggan secara signifikan, atau setelah intervensi program marketing tertentu. Segmentasi idealnya diperbarui setiap kuartal atau semester.

7. Pertimbangkan pengembangan fitur tambahan pada data, seperti riwayat digital, aktivitas pada aplikasi, atau skor kepuasan, untuk menghasilkan segmentasi yang lebih presisi dan kontekstual.
8. Eksplorasi algoritma clustering alternatif seperti DBSCAN, Hierarchical Clustering, atau Gaussian Mixture Models dalam proyek lanjutan, agar segmentasi dapat diuji stabilitasnya dan dibandingkan efektivitas antar metode.

DAFTAR PUSTAKA

- Abdul-Rahman, S., Kamal Arifin, N. F., Hanafiah, M., & Mutalib, S. (2021). Customer segmentation and profiling for life insurance using K-Modes clustering and decision tree classifier. *International Journal of Advanced Computer Science and Applications*, 12(9), 434–441. <https://www.ijacsa.thesai.org>
- Adiana, B. E., Soesanti, I., & Permanasari, A. E. (2018). Analisis Segmentasi Pelanggan Menggunakan Kombinasi RFM Model dan Teknik Clustering. *Jurnal Terapan Teknologi Informasi*, 2(1), 23–32. <https://doi.org/10.21460/jutei.2018.21.76>
- Alamsyah, A., Prasetyo, P. E., Sunyoto, S., Bintari, S. H., Saputro, D. D., Rohman, S., & Pratama, R. N. (2022). Customer Segmentation Using the Integration of the Recency Frequency Monetary Model and the K-Means Cluster Algorithm. *Scientific Journal of Informatics*, 9(2), 189–196. <https://doi.org/10.15294/sji.v9i2.39437>
- Davies, D. L., & Bouldin, D. W. (1979). A Cluster Separation Measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-1(2), 224–227. <https://doi.org/10.1109/TPAMI.1979.4766909>
- Fahrudin, N., & Rindiyani, R. (2024). Comparison of K-Medoids and K-Means Algorithms in Segmenting Customers based on RFM Criteria. *E3S Web of Conferences*, 484, 02008. <https://doi.org/10.1051/e3sconf/202448402008>
- Garima, Gulati, H., & Singh, P. K. (2015). Clustering techniques in data mining: A comparison.
- Gao, Y., Li, J., Zhang, X., & Wang, M. (2025). *Data-driven product innovation in the insurance industry: A customer-centric approach*. *Journal of Financial Innovation and Technology*, 8(1), 45–59. <https://doi.org/10.1016/j.jfit.2024.09.004>
- Gustriansyah, R., Suhandi, N., & Antony, F. (2020). Clustering optimization in RFM analysis Based on k-Means. *Indonesian Journal of Electrical Engineering and Computer Science*, 18(1), 470. <https://doi.org/10.11591/ijeecs.v18.i1.pp470-477>
- Jamal, & Yanto, D. (2019). Analisis RFM dan Algoritma K-Means untuk Clustering Loyalitas Customer. 9(1).
- Joung, H., & Kim, S. (2023). *Understanding customer preferences through explainable machine learning: Implications for insurance product development*. *International Journal of Consumer Studies*, 47(3), 332–344. <https://doi.org/10.1111/ijcs.12875>
- Karo, I. M. K., Dewi, S., Mardiana, M., Ramadhani, F., & Harliana, P. (2023). KMeans and K-Medoids Algorithm Comparison for Clustering Forest Fire Location in Indonesia. *Jurnal Ecotipe (Electronic, Control,*

- Telecommunication, Information, and Power Engineering), 10(1), 86–94.
<https://doi.org/10.33019/jurnalecotipe.v10i1.3896>
- Madhulatha, T. S. (2012). AN OVERVIEW ON CLUSTERING METHODS. IOSR Journal of Engineering, 02(04), 719–725.
<https://doi.org/10.9790/3021-0204719725>
- Manjunath, Y. S. K., & Kashef, R. F. (2021). Distributed clustering using multi-tier hierarchical overlay super-peer peer-to-peer network architecture for efficient customer segmentation. *Electronic Commerce Research and Applications*, 47, Article 101040.
<https://doi.org/10.1016/j.elerap.2021.101040>
- Mirantika, N., & Rijanto, E. (2023). Comparative Analysis of K-Means and KMedoids Algorithms in Determining Customer Segmentation Using RFM Model. 18.
- Murpratiwi, S. I., Agung Indrawan, I. G., & Aranta, A. (2021). Analisis Pemilihan Cluster Optimal dalam Segmentasi Pelanggan Toko Retail. *Jurnal Pendidikan Teknologi dan Kejuruan*, 18(2), 152.
<https://doi.org/10.23887/jptk-undiksha.v18i2.37426>
- Oti, E. U., Olusola, M. O., Eze, F. C., & Enogwe, S. U. (2021). Comprehensive Review of K-Means Clustering Algorithms. *International Journal of Advances in Scientific Research and Engineering*, 07(08), 64–69.
<https://doi.org/10.31695/IJASRE.2021.34050>
- Paembonan, S., & Abduh, H. (2021). Penerapan Metode Silhouette Coeficient Untuk Evaluasi Clustering Obat. 6(2).
- Perdana, S. A., Florentin, S. F., & Santoso, A. (2022). Analisis Segmentasi Pelanggan Menggunakan K-Means Clustering Studi Kasus Aplikasi Alfagift. *Sebatik*, 26(2), 446–457.
<https://doi.org/10.46984/sebatik.v26i2.1991>
- Pramudiansyah, A., & Munte, H. (2021). Segmentasi Pelanggan Menggunakan Algoritma K-Means Berdasarkan Model Recency Frequency Monetary. *JURNAL ILMIAH ILMU KOMPUTER*, 7(2), 06–19.
<https://doi.org/10.35329/jiik.v7i2.201>
- Prasetyo, S. S., Mustafid, M., & Hakim, A. R. (2020). Penerapan Fuzzy C-Means Kluster untuk Segmentasi Pelanggan E-Commerce dengan Metode Recency Frequency Monetary (RFM). *Jurnal Gaussian*, 9(4), 421–433.
<https://doi.org/10.14710/j.gauss.v9i4.29445>
- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65. [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7)
- Rungruang, C., Riyapan, P., Intarasit, A., Chuarkham, K., & Muangprathub, J. (2024). RFM model customer segmentation based on hierarchical approach using FCA. *Expert Systems with Applications*, 237, 121449.
<https://doi.org/10.1016/j.eswa.2023.121449>

- Sajidah, S., Herdiana, R., & Solihudin, D. (2023). Segmentasi Pelanggan Salon Nuii Beauty Glow Menggunakan K-Means Clustering. *JATI (Jurnal Mahasiswa Teknik Informatika)*, 7(1), 558–566. <https://doi.org/10.36040/jati.v7i1.6333>
- Silamantha, W. A., & Hadiono, K. (2024). Analisis RFM dan K-Means Clustering untuk Segmentasi Pelanggan pada PT. Sanutama Bumi Arto. 5(3).
- Syakur, M. A., Khotimah, B. K., Rochman, E. M. S., & Satoto, B. D. (2018). Integration K-Means Clustering Method and Elbow Method For Identification of The Best Customer Profile Cluster. *IOP Conference Series: Materials Science and Engineering*, 336, 012017. <https://doi.org/10.1088/1757-899X/336/1/012017>
- Teslenko, D., Sorokina, A., Smelyakov, K., & Filipov, O. (2023). Comparative Analysis of the Applicability of Five Clustering Algorithms for Market Segmentation. 2023 IEEE Open Conference of Electrical, Electronic and Information Sciences (eStream), 1–6. <https://doi.org/10.1109/eStream59056.2023.10134796>
- Tivano, D., Ruslianto, I., & Prawira, D. (2023). Sistem Segmentasi Pelanggan Potensial Menggunakan Metode K-Means dan Analisis RFM. *Coding Jurnal Komputer dan Aplikasi*, 11(3), 325. <https://doi.org/10.26418/coding.v11i03.53238>
- Tressa, N., Asha, V., Kumar, P., Shree, O., M, U. K., & Sreenivasa Reddy, V. V. (2024). Customer-Based Market Segmentation Using Clustering in Data mining. 2024 2nd International Conference on Intelligent Data Communication Technologies and Internet of Things (IDCIoT), 687–691. <https://doi.org/10.1109/IDCIoT59759.2024.10467258>
- Umargono, E., Suseno, J. E., & S. K., V. G. (2019). K-Means Clustering Optimization using the Elbow Method and Early Centroid Determination Based-on Mean and Median: Proceedings of the International Conferences on Information System and Technology, 234–240. <https://doi.org/10.5220/0009908402340240>
- Yum, K., Yoo, B., & Lee, J. (2022). Application of AI-based customer segmentation in the insurance industry. *Asia Pacific Journal of Information Systems*, 32(3), 496–513. <https://doi.org/10.14329/apjis.2022.32.3.496>

LAMPIRAN

Lampiran 1. Kontrak Kerja

DATA SCIENCE CONSULTING PROGRAM

PT Data Nusantara (Datara)
Jl. Danantara XXVII No.1, Surabaya, 14413
Telp:0812345678 | Fax : (023)4567
Email : customerinfo@datara.com

KONTRAK

Tanggal : 7 Mei 2025

Nama dan Alamat Konsultan:
Tim 12
Jl. Danantara XXVII No.1, Surabaya, 14413

Nama dan Alamat Klien:
PT AXA Mandiri Indonesia
AXA Tower Lt. GF
Jl. Prof. Dr. Satrio Kav. 18, Kuningan City
Jakarta 12940, Indonesia
via : general@axa-mandiri.co.id

Judul Proyek:

SMART-RFM: Segmentation for Marketing and Revenue Targeting – RFM pada AXA Mandiri Jakarta

Deskripsi Proyek:

Proyek ini merupakan bagian dari kegiatan Sains Data Consulting (SDC) dalam rangka penerapan analisis data untuk kebutuhan industri, khususnya di bidang asuransi. Proyek ini bertujuan untuk mengembangkan segmentasi pelanggan AXA Mandiri Jakarta menggunakan pendekatan Recency, Frequency, and Monetary (RFM) sebagai dasar perancangan strategi pemasaran dan pengembangan produk. Analisis dilakukan melalui tahapan pengolahan data, pemodelan clustering (K-Means), evaluasi, dan interpretasi bisnis dari hasil segmentasi.

Hak dan Kewajiban

Pihak Konsultan:

1. Melaksanakan seluruh proses analisis data sesuai metodologi yang telah disepakati.

2. Menjaga integritas, etika profesional, dan kerahasiaan data yang diberikan oleh perusahaan.
3. Menyusun dan menyerahkan laporan proyek tepat waktu sesuai dengan jadwal yang ditetapkan.
4. Berhak atas pembayaran sesuai perjanjian, wajib menjaga kerahasiaan data, dan berkewajiban menyelesaikan pekerjaan sesuai timeline dan kualitas deliverable.

Pihak Perusahaan (AXA Mandiri Jakarta):

1. Memberikan akses terhadap data dan konteks bisnis yang relevan untuk kebutuhan analisis.
2. Menyediakan data yang dibutuhkan, menerima hasil kerja, dan berhak meminta revisi minor maksimal 2 kali.
3. Memberikan umpan balik atas hasil segmentasi dan rekomendasi yang diberikan oleh tim mahasiswa.

Syarat dan Ketentuan

1. Revisi besar di luar scope awal akan dikenakan biaya tambahan.
2. Jika terjadi force majeure (bencana, kerusakan, dsb), jadwal dapat disesuaikan bersama.
3. Seluruh data klien bersifat rahasia dan tidak digunakan di luar proyek.

Ketentuan Pembatalan

Proyek dapat dibatalkan atas kesepakatan bersama. Jika dibatalkan sepihak setelah pekerjaan dimulai, pembayaran proporsional sesuai pekerjaan yang telah dilakukan tetap dibayarkan.

Penyelesaian Perselisihan

Segala perselisihan diselesaikan secara musyawarah mufakat. Jika tidak tercapai, dapat dibawa ke jalur hukum sesuai hukum yang berlaku di Indonesia.

Dengan ini, kedua belah pihak menyatakan telah membaca, memahami, dan menyetujui seluruh isi kontrak kerja sama ini. Klien setuju terhadap layanan dan ketentuan DATA SCIENCE CONSULTING PROGRAM (DSCP) sebagaimana dijelaskan dalam ringkasan proyek yang terlampir. Setelah layanan selesai, klien bersedia membayar biaya consulting sesuai dengan kesepakatan yang berlaku.

Dokumen ini ditandatangani secara sadar tanpa paksaan dari pihak manapun dan menjadi dasar hukum atas pelaksanaan proyek “SMART-RFM Segmentation for Marketing and Revenue Targeting – RFM AXA Mandiri Jakarta”.

Jakarta, 7 Mei 2025

Data Nusantara
Perwakilan Konsultan Tim 12

AXA Mandiri
Klien

Ketentuan Tambahan:

1. Seluruh keaslian data merupakan tanggung jawab dari klien
2. Keamanan dan privasi data merupakan tanggung jawab konsultan dan klien
3. Analisis yang dilakukan berupa segmentasi pelanggan asuransi PT. AXA Insurance Indonesia
4. Analisis berupa menggunakan model *clustering*
5. Pengerjaan proyek dilakukan oleh Tim 12 PT. Data
6. Pembayaran dilakukan dalam 2 termin:
Termin 1: 50% di awal proyek setelah penandatanganan kontrak.
Termin 2: 50% setelah seluruh deliverables diserahkan dan proyek dinyatakan selesai.
7. Pembayaran ditransfer ke rekening resmi tim Data Science Consulting, disertai bukti transfer.
8. Biaya sudah termasuk konsultasi online/offline, pembuatan dokumen, dan revisi minor (maksimal 2x)
9. Hal hal tambahan akan diinformasikan dan disesuaikan jika diperlukan

Tim 12 konsultan sains data perusahaan PT Data Nusantara (Data) beranggotakan sebagai berikut:

- | | |
|----------------------------------|----------------|
| ● Faqih Syamil | (162112133006) |
| ● Muhammad Yahya Oktaviyanto | (164221005) |
| ● Brahmantya Fikri Setya Putra | (164221034) |
| ● Mochammad Naufal Izah Ramadhan | (164221087) |
| ● Ananda Alvin Bernerdian | (164221196) |

Lampiran 2. Project Summary

DATA SCIENCE CONSULTING PROGRAM

PT Data Nusantara (Data)
Jl. Danantara XXVII No.1, Surabaya, 14413
Telp:0812345678 | Fax : (023)4567
Email : customerinfo@data.com

Project Summary

Tanggal : 7 Mei 2025

Nama dan Alamat Konsultan:

Konsultan : PT Data Nusantara (Datara)

Staff : Tim 12

Jl. Danantara XXVII No.1, Surabaya, 14413

Nama dan Alamat Klien:

PT AXA Mandiri

AXA Tower Lt. GF

Jl. Prof. Dr. Satrio Kav. 18, Kuningan City

Jakarta 12940, Indonesia

via : general@axa-mandiri.co.id

Ringkasan

Judul Proyek :

SMART-RFM: Segmentation for Marketing and Revenue Targeting – RFM pada AXA Mandiri Jakarta

Deliverable Proyek:

Proyek ini menghasilkan sejumlah keluaran utama yang disampaikan kepada pihak klien, meliputi :

1. Dokumen Laporan Lengkap Proyek: Berisi uraian menyeluruh mengenai proses pengerjaan proyek, mulai dari eksplorasi data, preprocessing, feature engineering, pemodelan clustering, hingga rekomendasi strategis untuk perusahaan. Laporan ini diserahkan dalam format PDF atau Word.
2. Dataset yang Telah Diproses: Dataset final yang telah dibersihkan, dinormalisasi, dan siap digunakan untuk analisis lebih lanjut. File dikirim dalam format Excel atau CSV.
3. Kode Program (Source Code) : Seluruh skrip Python yang digunakan dalam proyek, termasuk proses preprocessing, eksplorasi data, clustering, evaluasi, dan visualisasi, dilengkapi dokumentasi singkat. File disampaikan dalam format .py atau .ipynb (Jupyter Notebook).
4. Visualisasi dan Dashboard: Kumpulan visualisasi hasil clustering serta, jika memungkinkan, dashboard interaktif sederhana. Format file berupa PNG, JPG, atau Notebook interaktif.
5. Presentasi Akhir: Materi presentasi yang merangkum metodologi, hasil analisis, dan rekomendasi akhir kepada pihak klien, disampaikan dalam bentuk file PowerPoint (.pptx).
6. Dokumentasi Proyek: Berisi catatan kerja selama proyek berlangsung, termasuk timeline pengerjaan, pembagian tugas antar anggota tim, serta catatan kendala dan solusi yang dihadapi. Disusun dalam format PDF atau Word sebagai bentuk transparansi dan refleksi proses kerja.

Estimasi Kontrak : Rp32.500.000

Important

PT. Datara Indonesia mengasumsikan bahwa klien menyetujui estimasi biaya kontrak ini. Biaya tambahan dapat dikenakan jika diperlukan dan klien akan diinformasikan sebelum dilakukan pekerjaan tambahan tersebut. Apabila terjadi keterlambatan dalam pembayaran jasa DSCP oleh pihak klien maka akan dikenakan sanksi berupa denda sebesar Rp500.000/3 hari. Apabila terjadi keterlambatan dalam pengerjaan proyek oleh Pihak Konsultan maka akan dikenakan sanksi berupa denda sebesar Rp500.000/3hari.

Lampiran 3 Rincian Harga

No	Uraian	Satuan	Kuantitas	Harga Satuan (Rp)	Jumlah (Rp)
1	Konsultasi & Analisis Data	Paket	1	1.000.000	1.000.000
2	Staff Konsultan	Orang	5	5.000.000	25.000.000
3	Pengolahan & Preprocessing Data	Paket	1	1.500.000	1.500.000
4	Clustering & Modeling	Paket	1	2.000.000	2.000.000
5	Visualisasi & Dashboard	Paket	1	2.000.000	2.000.000
6	Laporan & Presentasi Akhir	Paket	1	1.000.000	1.000.000
Total Biaya Proyek					32.500.000