

Analisis Komprehensif Dinamika Indeks Pembangunan Manusia, Tingkat Pengangguran Terbuka, dan Kemiskinan di Indonesia: Studi Panel Antar Provinsi Tahun 2022–2024

Muhammad Yahya Oktaviyanto¹, Brahmantya Fikri
Setya Putra², Ananda Rafi Prasetyo³, Rexwald
Kamasean⁴, Fadli Muhammad⁵, Haryo Bismo
Wicaksono⁶

¹*Data Science Technology, Airlangga University,
Indonesia*

²*Data Science Technology, Airlangga University,
Indonesia*

³*Data Science Technology, Airlangga University,
Indonesia*

⁴*Data Science Technology, Airlangga University,
Indonesia*

⁵*Data Science Technology, Airlangga University,
Indonesia*

⁶*Data Science Technology, Airlangga University,
Indonesia*

Abstract—An abstract should be providing the basic content of a manuscript quickly and accurately. In addition, the abstract should be informative and self-explanatory. Furthermore, abstract should provide clear statement of the problem, proposed approach, major findings and conclusions. Moreover, the abstract should be 100 to 250 words in length, bold and 9pt.

Keywords—Indeks Pembangunan Manusia, Kemiskinan, Produk Domestik Rasio Bruto.

I. PENDAHULUAN

Indeks Pembangunan Manusia (IPM) merupakan indikator komprehensif yang digunakan untuk menilai kualitas hidup, kesehatan, pendidikan, dan standar hidup masyarakat di suatu wilayah. Di Indonesia, meskipun telah terjadi kemajuan pembangunan dalam beberapa dekade terakhir, masih terdapat ketimpangan signifikan antar provinsi, terutama terkait dengan tingkat pengangguran terbuka dan kemiskinan. Ketimpangan ini tidak hanya menunjukkan perbedaan kualitas hidup, tetapi

juga menandakan adanya tantangan dalam pemerataan hasil pembangunan di tingkat regional [1], [2].

IPM terdiri dari tiga dimensi utama, yaitu kesehatan (angka harapan hidup), pendidikan (rata-rata lama sekolah dan harapan lama sekolah), serta standar hidup (pengeluaran per kapita). Peningkatan IPM diharapkan dapat berdampak positif terhadap penurunan tingkat kemiskinan dan pengangguran, mengingat peningkatan kualitas hidup membuka lebih banyak kesempatan ekonomi bagi masyarakat.

Namun, dinamika IPM, tingkat pengangguran terbuka, dan kemiskinan tidak selalu berjalan searah di seluruh wilayah Indonesia. Periode 2022–2024 menjadi penting untuk dianalisis mengingat adanya pemulihan ekonomi pasca pandemi COVID-19 dan berbagai kebijakan pemerintah yang diarahkan untuk mempercepat pembangunan manusia serta mengatasi pengangguran dan kemiskinan di berbagai provinsi. Penelitian Paizal dkk. [3] menunjukkan adanya pengaruh signifikan IPM terhadap penurunan kemiskinan, tetapi hubungan antara IPM dan pengangguran masih memerlukan kajian lebih lanjut, khususnya dengan pendekatan data panel antar provinsi [1], [2].

Oleh karena itu, penelitian ini akan menganalisis secara komprehensif dinamika IPM, tingkat pengangguran terbuka, dan kemiskinan di seluruh provinsi di Indonesia selama periode 2022–2024. Studi panel ini diharapkan dapat memberikan gambaran yang lebih mendalam mengenai keterkaitan antar indikator pembangunan manusia di berbagai wilayah dan waktu, sekaligus memberikan masukan bagi perumusan kebijakan pembangunan yang lebih tepat sasaran guna meningkatkan kesejahteraan masyarakat Indonesia secara merata.

II. TINJAUAN PUSTAKA

A. Indeks Pembangunan Manusia

Indeks Pembangunan Manusia (IPM) merupakan indikator komposit yang mencerminkan kualitas hidup masyarakat melalui tiga dimensi utama yaitu umur panjang dan sehat, pendidikan yang layak, serta standar hidup yang memadai. IPM sering dijadikan parameter keberhasilan pembangunan manusia karena mencerminkan potensi sumber daya manusia dalam jangka panjang. Peningkatan IPM secara umum berdampak pada penurunan tingkat kemiskinan karena masyarakat yang lebih sehat, terdidik, dan memiliki pendapatan layak cenderung memiliki akses lebih besar terhadap peluang ekonomi. Menurut Rahmadhani [4], IPM memiliki peran sebagai variabel moderasi dalam memperkuat pengaruh inflasi dan pengangguran terhadap kemiskinan, meskipun pengaruhnya tidak bersifat langsung. Hal ini menunjukkan bahwa pembangunan manusia yang berkualitas harus diimbangi dengan pemerataan akses pendidikan dan kesehatan agar pengaruhnya terhadap pengurangan kemiskinan lebih signifikan [4], [5].

B. Tingkat Pengangguran Terbuka

Tingkat pengangguran terbuka merupakan indikator yang mengukur persentase penduduk usia kerja yang aktif mencari pekerjaan namun belum memperoleh pekerjaan.

Pengangguran terbuka sering kali dikaitkan langsung dengan tingkat kemiskinan karena ketidakmampuan individu untuk memperoleh penghasilan tetap. Dalam studi Kholis dan Gunarto [5], ditemukan bahwa pengangguran memiliki pengaruh signifikan terhadap kemiskinan di Provinsi Lampung, mempertegas bahwa ketidakserapan tenaga kerja menjadi faktor utama yang memperparah kondisi sosial ekonomi. Meski begitu, sebagaimana dijelaskan oleh Naufal [6], tidak semua wilayah menunjukkan korelasi langsung antara pengangguran terbuka dan kemiskinan, mengindikasikan adanya peran dari sektor informal dan bantuan sosial. Dengan demikian, penanganan pengangguran membutuhkan kebijakan yang lebih terfokus seperti peningkatan pelatihan kerja dan penciptaan lapangan kerja produktif agar potensi manusia yang telah dikembangkan melalui IPM dapat benar-benar dimanfaatkan secara optimal.

C. Tingkat Kemiskinan

Tingkat kemiskinan merujuk pada persentase penduduk yang hidup dalam kondisi tidak mampu memenuhi kebutuhan dasar hidup seperti makanan, pakaian, pendidikan, dan tempat tinggal. Indikator ini mencerminkan tingkat kesejahteraan suatu wilayah dan digunakan oleh pemerintah untuk merancang kebijakan sosial dan ekonomi. Menurut Dewintha, Yahya, dan Ihwal [7], tingkat kemiskinan di berbagai provinsi di Indonesia sangat dipengaruhi oleh variabel seperti pengangguran, pendidikan, dan inflasi, yang menyebabkan penduduk sulit mencapai tingkat pengeluaran minimum yang layak. Selain itu, Nurjanah [8] menekankan bahwa angka kemiskinan tidak hanya bersifat kuantitatif, tetapi juga mencerminkan struktur sosial dan distribusi sumber daya yang tidak merata. Oleh karena itu, pengukuran dan pemantauan tingkat kemiskinan harus dilakukan secara berkelanjutan dan disertai dengan intervensi yang terarah.

D. Regresi Linier

Regresi linier adalah metode statistik yang bertujuan untuk menjelaskan hubungan antara satu variabel dependen dan satu atau lebih variabel independen secara linier. Model ini cocok digunakan untuk analisis pengaruh variabel sosial-ekonomi seperti IPM dan pengangguran terhadap kemiskinan. Bentuk umum dari regresi linier berganda adalah:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \varepsilon$$

di mana Y adalah variabel dependen (misalnya tingkat kemiskinan atau pengangguran), $X_1, X_2, \dots, X_n$ adalah variabel independen (misalnya IPM), β_0 adalah intersep, $\beta_1, \dots, \beta_n$ adalah koefisien regresi, dan ε adalah error atau residual yang diasumsikan berdistribusi normal.

Model ini banyak digunakan dalam studi kuantitatif sosial. Sihombing [9] menggunakan regresi linier untuk memetakan hubungan antara kemiskinan dan variabel makroekonomi di Sumatera Utara, dan menemukan bahwa IPM dan pengangguran berpengaruh signifikan terhadap tingkat kemiskinan.

E. Regresi Spasial

Berbeda dari regresi linier klasik, regresi spasial mempertimbangkan aspek geografis atau lokasi dalam analisisnya, yakni ketika data antar wilayah menunjukkan keterkaitan atau autokorelasi spasial. Dalam konteks pembangunan daerah, hal ini penting karena suatu wilayah tidak berdiri sendiri—pembangunan di suatu provinsi bisa dipengaruhi oleh kondisi provinsi tetangganya. Tarigan [10] menjelaskan bahwa dengan menggunakan model Spatial Autoregressive (SAR) dan Spatial Error Model (SEM), analisis terhadap IPM dan kemiskinan di Sumatera Utara menjadi lebih akurat karena mempertimbangkan pengaruh lokasi.

E.1 Spatial Lag Model (SLM)

$$Y = \rho W Y + X \beta + \varepsilon$$

di mana Y adalah vektor variabel dependen, ρ adalah koefisien autokorelasi spasial yang menunjukkan seberapa besar pengaruh variabel dependen di wilayah sekitar terhadap wilayah yang diteliti. W adalah matriks bobot spasial yang merepresentasikan kedekatan atau keterhubungan antar wilayah, sehingga WY menunjukkan lag spasial dari variabel dependen (yakni nilai rata-rata dari variabel dependen di wilayah tetangga). X adalah matriks variabel independen, β adalah vektor koefisien regresi untuk variabel independen, dan ε adalah error term yang mencerminkan komponen galat acak atau faktor yang tidak dijelaskan oleh model.

E.2 Spatial Error Model (SEM):

$$Y = X\beta + \mu, \mu = \lambda W \mu + \varepsilon$$

di mana Y adalah variabel dependen, X adalah matriks variabel independen, β adalah vektor koefisien regresi, μ merupakan komponen galat yang mengandung autokorelasi spasial, λ adalah koefisien autokorelasi dari error term, W adalah matriks bobot spasial, dan ε adalah error acak (white noise).

SEM mampu mengungkap pola yang tidak bisa ditangkap oleh regresi biasa, seperti konsentrasi wilayah IPM rendah yang dikelilingi oleh wilayah serupa. Dengan demikian, model ini berguna untuk merumuskan kebijakan pembangunan berbasis wilayah yang lebih terarah dan efektif.

F. K-Means Clustering

K-Means Clustering merupakan salah satu metode unsupervised learning yang digunakan untuk mengelompokkan data ke dalam sejumlah klaster berdasarkan kemiripan karakteristik. Metode ini bekerja dengan mencari pusat klaster (centroid) secara iteratif, kemudian mengelompokkan data berdasarkan jarak terdekat ke masing-masing centroid hingga tercapai konvergensi. Dalam konteks penelitian sosial ekonomi, K-Means sering dimanfaatkan untuk mengklasifikasikan wilayah atau provinsi berdasarkan indikator tertentu seperti IPM, tingkat pengangguran terbuka, dan kemiskinan, dengan tujuan menghasilkan segmentasi wilayah yang memiliki kesamaan pola karakteristik pembangunan. Kelebihan metode ini adalah kesederhanaan implementasinya dan efisiensinya dalam menangani data berukuran besar, meskipun jumlah klaster harus ditentukan di awal dan hasilnya sensitif terhadap inisialisasi centroid. Menurut Wibisono dan Susetyo [11], penerapan K-Means dalam analisis pembangunan regional

memungkinkan identifikasi daerah yang membutuhkan intervensi kebijakan lebih terfokus berdasarkan kondisi agregat wilayahnya.

III. METODOLOGI

A. Jenis dan Sumber Data

Penelitian ini menggunakan data kuantitatif sekunder yang dikumpulkan dari sumber resmi milik pemerintah, yaitu Badan Pusat Statistik (BPS) dan Open Data Jawa Barat. Data diperoleh untuk periode 2022 hingga 2024 dan mencakup seluruh provinsi di Indonesia. Sumber data yang digunakan antara lain: Data Indeks Pembangunan Manusia (IPM) per provinsi dari BPS [12]. Data Tingkat Pengangguran Terbuka (TPT) per provinsi dari BPS [13]. Data Persentase Penduduk Miskin per provinsi dari portal Open Data Provinsi Jawa Barat [14]. Seluruh data memiliki cakupan provinsi dan tahun yang konsisten, sehingga memungkinkan dilakukan pengujian hubungan antar variabel dalam ruang lingkup panel data sederhana.

B. Populasi dan Sampel

Jumlah provinsi di Indonesia saat ini adalah 38 provinsi, seiring dengan pemekaran wilayah administratif terbaru. Namun, dalam penelitian ini hanya digunakan 34 provinsi sebagai sampel analisis. Hal ini disebabkan karena empat provinsi baru hasil pemekaran (Provinsi Papua Selatan, Papua Pegunungan, Papua Tengah, dan Papua Barat Daya) belum memiliki data lengkap dan konsisten untuk variabel IPM, kemiskinan, dan pengangguran pada rentang tahun 2022–2024.

Oleh karena itu, penelitian ini menggunakan pendekatan studi populasi terbatas, yaitu terhadap 34 provinsi yang telah memiliki data lengkap selama 3 tahun. Dengan demikian, jumlah observasi dalam panel data adalah:

$$34 \times 3 = 102 \text{ Observasi}$$

C. Regresi Berganda

C.1 Uji Asumsi

Untuk memastikan validitas dan reliabilitas model regresi linear berganda, dilakukan pengujian terhadap asumsi klasik regresi. Pengujian dilakukan terhadap empat asumsi utama: normalitas residual, multikolinearitas, heteroskedastisitas, dan autokorelasi residual. Pemilihan metode pengujian didasarkan pada efektivitas dan ketepatannya dalam mendeteksi pelanggaran asumsi dengan karakteristik data yang digunakan.

C.1.1 Uji Distribusi Normal

Uji normalitas bertujuan untuk memastikan bahwa residual dari model regresi terdistribusi secara normal. Salah satu uji yang umum digunakan adalah Shapiro-Wilk Test. Uji ini dikenal dengan daya deteksi yang tinggi, terutama untuk sampel kecil hingga menengah, dan sangat sensitif terhadap skewness atau kurtosis pada distribusi residual. Penelitian terbaru mengonfirmasi bahwa nilai p dari uji Shapiro-Wilk di bawah 0.05 menunjukkan bahwa residual mengikuti distribusi normal, yang penting untuk validitas hasil regresi [15].

Hipotesis:

H_0 : Residual berdistribusi normal

H_1 : Residual tidak berdistribusi normal

Kriteria keputusan: Jika nilai $p > 0.05$, maka tidak terdapat cukup bukti untuk menolak H_0 , sehingga dapat disimpulkan bahwa residual terdistribusi normal.

C.1.2. Uji Multikolinearitas

Uji multikolinearitas bertujuan untuk mengetahui adanya hubungan linier yang kuat antar variabel independen. Salah satu alat yang sering digunakan adalah Variance Inflation Factor (VIF). Penelitian terkini menunjukkan bahwa VIF lebih besar dari 10 menunjukkan adanya multikolinearitas yang perlu diatasi dalam model regresi [16].

Interpretasi:

$VIF < 10 \rightarrow$ Tidak ada indikasi multikolinearitas

$VIF \geq 10 \rightarrow$ Menunjukkan adanya multikolinearitas tinggi yang harus diatasi

C.1.3. Uji Heteroskedastisitas

Uji heteroskedastisitas digunakan untuk memeriksa apakah varians residual bersifat konstan. Breusch-Pagan Test adalah metode yang sangat kuat untuk mendeteksi adanya hubungan sistematis antara residual dan variabel independen. Penelitian menunjukkan bahwa jika nilai p lebih besar dari 0.05, tidak ada bukti yang cukup untuk menolak hipotesis nol yang menyatakan tidak adanya heteroskedastisitas [17].

Hipotesis:

H_0 : Tidak terjadi heteroskedastisitas (residual memiliki varians konstan)

H_1 : Terjadi heteroskedastisitas

Kriteria keputusan: Jika nilai $p > 0.05$, maka tidak terdapat bukti cukup untuk menolak H_0 sehingga disimpulkan tidak terdapat heteroskedastisitas.

C.1.4. Uji Autokorelasi

Uji autokorelasi digunakan untuk mengidentifikasi apakah terdapat korelasi antara residual dan nilai lag-nya, yang sering terjadi dalam data time series. Durbin-Watson Test adalah metode yang paling banyak digunakan untuk mendeteksi autokorelasi orde pertama. Penelitian terbaru menunjukkan bahwa nilai Durbin-Watson berada dalam kisaran yang aman antara 1.5 hingga 2.5, yang menunjukkan bahwa tidak ada masalah autokorelasi [18].

Interpretasi nilai Durbin-Watson (DW):

$DW \approx 2 \rightarrow$ Tidak ada autokorelasi

$DW < 1.5 \rightarrow$ Indikasi autokorelasi positif

$DW > 2.5 \rightarrow$ Indikasi autokorelasi negatif

C.1.5 Uji Korelasi Spearman

koefisien Spearman sangat efektif dalam mengukur asosiasi ketika bentuk hubungan tidak diketahui secara pasti, namun diyakini memiliki pola naik/turun yang tetap (monotonik) [19]. Adapun rumusnya sebagai berikut:

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2-1)}$$

Koefisien korelasi Spearman (ρ) digunakan untuk mengukur kekuatan dan arah hubungan monotonik antara dua variabel, misalnya antara IPM dan TPT antar provinsi. Nilai ρ dihitung berdasarkan selisih ranking dari masing-masing observasi ke- i , yang dilambangkan dengan d_i^2 , yaitu perbedaan peringkat antara dua variabel untuk tiap provinsi. Jumlah total observasi yang diamati, yaitu jumlah provinsi, dilambangkan dengan n .

C.1 Linear Regression

Metode regresi linear digunakan sebagai pendekatan awal untuk memodelkan hubungan antarvariabel secara sederhana dan interpretable. Dalam penelitian ini, regresi linear diterapkan pada tiga kombinasi hubungan: (1) IPM sebagai variabel independen untuk memprediksi TPT, (2) TPT sebagai variabel independen untuk memprediksi IPM, dan (3) gabungan IPM dan TPT sebagai prediktor terhadap tingkat kemiskinan. Regresi linear diasumsikan mampu menangkap keterkaitan linier antara variabel-variabel tersebut. Evaluasi performa dilakukan dengan melihat nilai R^2 , MSE, dan MAE untuk mengetahui sejauh mana model ini dapat menjelaskan variabilitas data dan akurasi prediksi. Adapun Rumus Linear regression adalah sebagai berikut:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \epsilon$$

persamaan regresi linear di atas menggambarkan hubungan antara satu variabel dependen (Y) dengan satu atau lebih variabel independen ($X_1, X_2, \dots, X_n$). Dalam model ini, Y merupakan variabel dependen atau variabel yang ingin diprediksi atau dijelaskan. Variabel X_1 hingga X_n adalah variabel independen, yaitu faktor-faktor yang mempengaruhi nilai Y . β_0 adalah intercept, yaitu nilai Y saat seluruh variabel independen bernilai nol. Sementara itu, β_1 hingga β_n merupakan koefisien regresi yang menunjukkan besarnya pengaruh masing-masing variabel independen terhadap Y . Terakhir, ϵ melambangkan error atau residual, yaitu selisih antara nilai Y yang sebenarnya dengan nilai Y yang diprediksi oleh model, mencerminkan variasi yang tidak dapat dijelaskan oleh variabel-variabel independen.

C.2 Tree-Based Regressor

Pendekatan tree-based seperti Decision Tree Regressor dan Random Forest Regressor digunakan untuk menangkap hubungan non-linier antara IPM, TPT, dan tingkat kemiskinan. Model ini mampu mengatasi kompleksitas data tanpa membutuhkan asumsi distribusi, serta secara otomatis mendeteksi interaksi antarfitur. Ketiga kombinasi hubungan diuji menggunakan tree-based model ini, dan performanya dibandingkan dengan model linear. Kelebihan utama pendekatan ini terletak pada fleksibilitas dan interpretabilitas struktur pohon dalam menggambarkan keputusan yang mendasari prediksi. Konsep utamanya adalah

$$\hat{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

nilai ini dihitung sebagai rata-rata dari nilai-nilai target aktual y_i yang termasuk dalam node (daun) yang sama dalam struktur pohon keputusan. Simbol y_i merujuk pada nilai target

atau variabel dependen dari data ke- i yang berada di dalam node tersebut. Sementara itu, n menunjukkan jumlah total data pelatihan yang masuk ke dalam node tersebut. Dalam konteks ini, setiap prediksi didasarkan pada kumpulan data yang memiliki karakteristik serupa, yang secara otomatis dikelompokkan oleh pohon berdasarkan pembagian variabel independen.

C.3 Support Vector Regression (SVR)

Support Vector Regression diterapkan untuk mengevaluasi apakah model dengan margin error terbatas (epsilon-insensitive) dapat lebih efektif dalam memodelkan hubungan antar IPM, TPT, dan kemiskinan. SVR dirancang untuk bekerja baik pada data dengan dimensi tinggi dan ketidakaturan, serta mampu memodelkan hubungan kompleks meskipun ukuran sampel terbatas. Model SVR diuji dalam ketiga kombinasi hubungan, dan performanya dibandingkan menggunakan metrik yang sama. Parameter kernel dan regularisasi dioptimalkan untuk meningkatkan akurasi dan menghindari overfitting.

$$f(x) = \sum_{i=1}^n (\alpha_i - \alpha_i^*) K(x_i, x) + b$$

nilai ini dihitung dari kombinasi kernel antara data input x dengan data pelatihan x_i . Di dalam rumus tersebut, α_i dan α_i^* adalah koefisien Lagrange yang diperoleh dari proses pelatihan SVR dan mencerminkan kontribusi masing-masing data pelatihan terhadap prediksi. Fungsi $K(x_i, x)$ adalah fungsi kernel yang mengukur kesamaan antara titik data x dan titik data pelatihan x_i , dengan bentuk kernel bisa berupa linear, polynomial, atau radial basis function (RBF) tergantung pada konfigurasi model. Simbol n menunjukkan jumlah total data pelatihan yang digunakan dalam model. Sementara itu, b adalah bias atau konstanta yang menyesuaikan posisi hyperplane dalam ruang fitur. Keseluruhan rumus ini memungkinkan model SVR untuk membuat prediksi berdasarkan kontribusi data pelatihan yang relevan dalam batas toleransi error tertentu (epsilon), yang bertujuan meminimalkan kesalahan tanpa terlalu sensitif terhadap outlier.

C.4 K-Nearest Neighbors Regressor (KNN)

Model KNN Regressor digunakan untuk mengeksplorasi pendekatan berbasis instance, yang membuat prediksi berdasarkan kedekatan data baru terhadap data yang sudah ada. Dalam konteks hubungan antar IPM, TPT, dan kemiskinan, KNN memanfaatkan pola lokal di sekitar titik data untuk menentukan nilai output. Model ini sangat berguna ketika hubungan antar variabel bersifat non-parametrik atau tidak diketahui bentuknya. Evaluasi dilakukan pada tiga arah hubungan yang sama, dan kinerja KNN dibandingkan untuk melihat apakah pendekatan berbasis tetangga terdekat memberikan hasil prediksi yang lebih baik.

$$\hat{y} = \frac{1}{k} \sum_{i \in N_k(x)} y_i$$

dalam model K-Nearest Neighbors Regressor (KNN) yang dijelaskan di atas, prediksi nilai keluaran $\hat{y}$ untuk suatu data

baru x dilakukan dengan menghitung rata-rata dari nilai target y_i milik k tetangga terdekat. Dalam konteks hubungan antar indikator seperti Indeks Pembangunan Manusia (IPM), Tingkat Pengangguran Terbuka (TPT), dan kemiskinan, pendekatan ini memanfaatkan data-data daerah yang memiliki pola serupa atau jarak data yang berdekatan dalam ruang fitur. Himpunan $N_k(x)$ merepresentasikan kumpulan tetangga-tetangga terdekat dari titik data x , yang didapat berdasarkan perhitungan jarak—biasanya menggunakan Euclidean Distance. Perhitungan Euclidean dapat dihitung dengan rumus:

$$d(x_i, x) = \sqrt{\sum_{j=1}^n (x_i - x_{ij})^2}$$

D. K-Means Clustering

D.1 Tujuan Clustering

Clustering dilakukan untuk mengelompokkan provinsi-provinsi di Indonesia berdasarkan kesamaan karakteristik sosial ekonomi, khususnya Indeks Pembangunan Manusia (IPM), tingkat kemiskinan, dan tingkat pengangguran terbuka (TPT). Dengan teknik ini, pola kemiripan antar provinsi dapat dikenali sehingga memudahkan analisis serta perumusan kebijakan yang lebih tepat sasaran.

D.2 Pra-pemrosesan Data

Data IPM, kemiskinan, dan TPT dari masing-masing provinsi terlebih dahulu distandarisasi menggunakan teknik scaling. Standarisasi ini penting untuk memastikan setiap indikator memiliki pengaruh yang seimbang dalam proses pengelompokan.

D.3 Proses K-Means++

Metode K-Means++ digunakan untuk melakukan proses clustering karena mampu memberikan inisialisasi pusat cluster yang lebih baik dan hasil segmentasi yang lebih optimal. Algoritma ini dijalankan pada data yang sudah distandarisasi untuk menghasilkan pengelompokan provinsi ke dalam kluster-kluster yang serupa.

D.4 Penentuan Jumlah Kluster

Jumlah kluster optimal ditentukan menggunakan Elbow Method. Metode ini menganalisis perubahan nilai inerti untuk berbagai jumlah kluster dan memilih titik di mana penurunan inerti mulai melandai. Pada penelitian ini, diperoleh lima kluster sebagai segmentasi terbaik untuk data yang dianalisis.

D.5 Evaluasi Model

Evaluasi hasil clustering dilakukan dengan menggunakan Silhouette Score. Nilai ini mengukur seberapa baik pemisahan antar kluster yang terbentuk. Silhouette Score rata-rata sebesar 0,389 menunjukkan bahwa pemisahan kluster sudah cukup baik, meskipun masih terdapat beberapa tumpang tindih antar kluster.

D.6 Interpretasi Hasil

Setelah proses clustering, masing-masing kluster dianalisis berdasarkan rata-rata IPM, tingkat kemiskinan, dan TPT yang dimiliki. Analisis ini digunakan untuk memahami karakteristik utama dan tantangan setiap kelompok provinsi, sehingga dapat

digunakan sebagai dasar perumusan kebijakan yang lebih efektif dan tepat sasaran.

E. Analisis Geospasial

E.1. Tujuan Analisis Geospasial

Analisis geospasial dalam penelitian ini bertujuan untuk mengidentifikasi pola, hubungan, dan tren spasial dari variabel-variabel sosial ekonomi, khususnya tingkat kemiskinan, IPM, dan TPT antar provinsi di Indonesia. Dengan analisis ini, diharapkan dapat diketahui apakah terdapat pengelompokan wilayah dengan karakteristik serupa, serta adanya pengaruh spasial antar lokasi yang berdekatan.

E.2. Pemetaan dan Visualisasi Data

Langkah awal analisis geospasial dilakukan dengan memetakan data tingkat kemiskinan rata-rata di seluruh provinsi Indonesia menggunakan peta tematik. Visualisasi ini membantu dalam mengidentifikasi disparitas spasial dan mengenali wilayah dengan tingkat kemiskinan tinggi, sedang, maupun rendah. Warna dan gradasi pada peta merepresentasikan nilai variabel kemiskinan sehingga memudahkan interpretasi pola geografis secara visual.

E.3. Uji Autokorelasi Spasial (Moran's I)

Untuk menguji apakah terdapat autokorelasi spasial yakni, kecenderungan nilai suatu variabel pada satu wilayah dipengaruhi oleh nilai variabel di wilayah sekitarnya digunakan Uji Moran. Prosedur ini melibatkan perhitungan statistik Moran's I dan pengujian signifikansi p-value. Nilai p-value yang rendah menunjukkan adanya pola spasial yang signifikan dalam data, sehingga pendekatan spasial lebih lanjut diperlukan dalam analisis regresi.

E.4. Model Regresi Spasial

Setelah autokorelasi spasial terdeteksi, penelitian ini melanjutkan dengan penerapan model regresi spasial, yakni Spatial Error Model (SEM) dan Spatial Lag Model (SLM). Analisis ini bertujuan untuk mengakomodasi efek spasial pada variabel-variabel yang dianalisis, agar hasil estimasi model lebih akurat dan dapat mencerminkan pengaruh lokasi geografis.

E.5. Evaluasi Model

Kinerja masing-masing model regresi spasial dievaluasi menggunakan metrik seperti R^2 , RMSE, MSE, MAE, dan MAPE. Model dengan nilai R^2 lebih tinggi dan RMSE lebih rendah dipilih sebagai model terbaik untuk menjelaskan hubungan antara variabel-variabel dalam konteks spasial. Selain itu, signifikansi masing-masing variabel independen terhadap variabel dependen diuji menggunakan p-value.

IV. HASIL DAN PEMBAHASAN

Pada bagian ini akan dipaparkan hasil-hasil analisis yang telah dilakukan terhadap data penelitian. Pembahasan dibagi menjadi dua bagian utama, yaitu analisis regresi linier untuk melihat hubungan antar variabel, serta analisis clustering untuk mengelompokkan provinsi berdasarkan kemiripan karakteristik indikator pembangunan.

A. Analisis Regresi

A.1 Uji Asumsi

A.1.1. Uji Normalitas

Tabel A1.1. Tabel Hasil Uji Normalitas

Variabel	Statistik	Sig.
IPM	0.92	0.00
TPT	0.95	0.00
Kemiskinan	0.90	0.00

Hasil uji normalitas menunjukkan bahwa nilai signifikansi (Sig.) untuk ketiga variabel (IPM, TPT, dan Kemiskinan) berada di bawah 0.05, masing-masing 0.000, 0.00, dan 0.000. Hal ini menunjukkan bahwa data dari ketiga variabel tidak berdistribusi normal. Dengan demikian, asumsi normalitas tidak terpenuhi, yang berarti analisis regresi linier klasik mungkin tidak optimal tanpa transformasi atau pendekatan robust lainnya.

A.1.2. Uji Multikolinearitas

Tabel A1.2. Tabel Hasil Uji Multikolinearitas

Variabel	VIF	Toleransi	Interpretasi
IPM	21.04	0.04	Tinggi
TPT	14.09	0.07	Tinggi
Kemiskinan	4.98	0.20	Rendah

Hasil uji multikolinearitas memperlihatkan bahwa variabel IPM dan TPT memiliki nilai VIF yang sangat tinggi (21.045 dan 14.095), serta toleransi yang rendah (0.048 dan 0.071), yang mengindikasikan adanya multikolinearitas tinggi antar keduanya. Sebaliknya, variabel Kemiskinan memiliki nilai VIF lebih rendah (4.989) dan toleransi sebesar 0.200, menunjukkan bahwa multikolinearitas pada variabel ini tergolong rendah. Oleh karena itu, perlu diwaspadai hubungan antar variabel independen yang terlalu kuat, terutama antara IPM dan TPT, karena dapat mengganggu estimasi regresi.

A.1.3. Uji Autokorelasi

Tabel A1.3. Tabel Hasil Uji Autokorelasi

Variabel	Lag 1	Lag 2	Lag 3	Interpretasi
IPM	0.702	0.443	0.223	Tinggi
TPT	0.53	0.13	-0.15	Tinggi
Kemiskinan	0.74	0.52	0.33	Tinggi

Uji autokorelasi dilakukan terhadap tiga lag untuk masing-masing variabel. Hasilnya menunjukkan bahwa semua variabel (IPM, TPT, dan Kemiskinan) memiliki nilai korelasi yang cukup tinggi di setiap lag, terutama pada Lag 1 dan Lag 3. Nilai korelasi yang tinggi ini menunjukkan adanya autokorelasi dalam data, yang mengindikasikan bahwa nilai-nilai sebelumnya dari suatu variabel mempengaruhi nilai saat ini. Autokorelasi yang tinggi dapat menjadi indikasi pelanggaran asumsi independensi error dalam regresi, sehingga perlu dipertimbangkan penggunaan model time series atau modifikasi lainnya.

A.1.4. Uji Heteroskedastisitas

Tabel A1.4. Tabel Hasil Uji Heteroskedastisitas

Test	Statistik	p-value	Interpretasi
Breusch-Pagan LM	3.49	0.06	Gagal Tolak H0
Breusch-Pagan F	3.54	0.06	Gagal Tolak H0

Uji heteroskedastisitas dilakukan menggunakan dua metode, yaitu Breusch-Pagan LM dan Breusch-Pagan F. Kedua uji menghasilkan nilai p-value sebesar 0.06, yang lebih besar dari tingkat signifikansi umum 0.05. Dengan demikian, keputusan yang diambil adalah gagal menolak H0 (hipotesis nol), yang berarti tidak terdapat cukup bukti untuk menyatakan adanya heteroskedastisitas dalam model. Artinya, asumsi homoskedastisitas terpenuhi, dan varians error dapat dianggap konstan di seluruh observasi, sehingga model regresi tidak mengalami permasalahan terkait varians residual yang tidak stabil.

A.1.5. Uji Korelasi Spearman

Tabel A.1.5 Tabel Skor Korelasi Spearman Antar Variabel

Variabel	IPM	TPT	Kemiskinan
IPM	1.00	0.39	-0.31
TPT	0.39	1.00	-0.53
Kemiskinan	-0.31	-0.53	1.00

Tabel A.1.5 menunjukkan skor korelasi Spearman antara variabel IPM, TPT, dan kemiskinan. Berdasarkan hasil perhitungan, korelasi antara IPM dan kemiskinan bernilai negatif sebesar -0.31, yang mengindikasikan adanya hubungan linier berlawanan arah dengan kekuatan lemah; semakin tinggi IPM suatu daerah, cenderung semakin rendah tingkat kemiskinan. Korelasi antara IPM dan TPT tercatat positif sebesar 0.39, menunjukkan hubungan linier lemah, meskipun mendekati kategori sedang. Sementara itu, korelasi antara TPT dan kemiskinan sebesar -0.53 termasuk dalam kategori sedang dan negatif, yang mengindikasikan bahwa peningkatan pengangguran cenderung diikuti oleh penurunan kemiskinan. Temuan ini perlu dianalisis lebih lanjut karena secara konseptual hubungan antara pengangguran dan kemiskinan seharusnya bersifat searah, sehingga kemungkinan terdapat variabel antara atau distorsi data.

Secara keseluruhan, dari ketiga pasangan variabel, hanya hubungan antara TPT dan kemiskinan yang menunjukkan kekuatan asosiasi sedang, sementara dua hubungan lainnya, yaitu IPM-TPT dan IPM-kemiskinan, menunjukkan hubungan linier yang lemah. Hal ini menandakan bahwa hubungan antar variabel belum cukup kuat untuk disimpulkan secara sederhana.

Sehubungan dengan hasil uji asumsi klasik yang menunjukkan bahwa sebagian besar asumsi model regresi linear berganda tidak terpenuhi, maka pendekatan regresi linear berganda tidak dijadikan sebagai model utama dalam penentuan model terbaik. Namun, untuk keperluan pembandingan dan eksplorasi awal, model regresi linear berganda tetap diasumsikan memenuhi asumsi dan digunakan

secara terbatas, tanpa dimasukkan ke dalam pemodelan akhir. Model regresi alternatif yang lebih sesuai dengan karakteristik data akan diutamakan dalam pemilihan model terbaik.

A.2 Regresi IPM & TPT terhadap Tingkat Kemiskinan

Tabel A.2 Evaluasi Model Regresi IPM & TPT terhadap Tingkat Kemiskinan (10 Hasil Terbaik)

Trans.	Model	R2	RMSE	MSE	MAE	MAPE
Yeo-Johnson	SVR	0.59	3.04	9.80	2.25	24.38
Inverse	SVR	0.56	3.14	10.35	2.35	24.62
Square-root	SVR	0.56	3.15	10.43	2.36	24.99
Log	SVR	0.55	3.18	10.70	2.37	25.43
Square-root	SVR	0.55	0.47	0.23	0.37	12.50
Yeo-Johnson	SVR	0.54	0.66	0.44	0.52	85.75
Original	SVR	0.53	3.24	11.11	2.43	26.35
Yeo-Johnson	Extra Trees	0.53	3.28	11.35	2.46	27.60
Yeo-Johnson	SVR	0.53	0.66	0.45	0.53	84.51
Exponential	SVR	0.52	3.26	11.23	2.45	26.66

Penelitian ini menguji 625 kombinasi model dan transformasi data untuk mengeksplorasi hubungan antara Indeks Pembangunan Manusia (IPM), Tingkat Pengangguran Terbuka (TPT), dan tingkat kemiskinan antar provinsi di Indonesia periode 2022–2024. Hasil evaluasi menunjukkan bahwa pendekatan terbaik diperoleh melalui kombinasi transformasi Yeo-Johnson pada variabel prediktor (X) dengan Support Vector Regression (SVR) menggunakan kernel radial basis function (RBF) dan 100 estimator (SVR_RBF_100).

Model terbaik ini mencapai skor R^2 sebesar 0.5514, yang menunjukkan bahwa hampir 55% variasi kemiskinan dapat dijelaskan oleh IPM dan TPT. Selain itu, nilai RMSE sebesar 0.4768, MAE sebesar 0.2327, dan MAPE sebesar 12.50% mengindikasikan akurasi prediksi yang tinggi dengan kesalahan relatif yang rendah. Dengan kata lain, model ini memiliki kombinasi optimal antara kekuatan penjelasan dan akurasi prediksi.

Transformasi Yeo-Johnson menunjukkan kinerja terbaik dibandingkan transformasi lain seperti Log, Reciprocal, dan Box-Cox karena mampu menangani nilai nol dan negatif, serta meningkatkan normalitas dan homoskedastisitas data. Hal ini relevan karena persebaran IPM dan TPT antarprovinsi di Indonesia sering kali tidak normal akibat ketimpangan regional yang tinggi, terutama antara wilayah barat dan timur.

A.3 Regresi IPM terhadap TPT

Tabel A.3. Evaluasi Model Regresi IPM terhadap TPT
(10 Hasil Terbaik)

Trans.	Model	R2	RMSE	MSE	MAE	MAPE
Poli-nomial	Linear	0.12	0.22	1.64	1.05	24.29
Original	KNN	0.12	0.24	1.67	1.04	24.27
Log. Poli-nomial	KNN	0.11	0.24	1.68	1.04	24.34
Square-Root	KNN	0.11	0.24	1.68	1.04	24.34
Log	KNN	0.11	0.24	1.68	1.04	24.34
Yeo-John-son	KNN	0.11	0.24	1.68	1.04	24.35
Box-Cox	KNN	0.11	0.24	1.68	1.04	24.35
Polin-omial	KNN	0.11	0.24	1.68	1.04	24.39
Polin-omial	KNN	0.11	0.25	1.69	1.04	24.43
Invers	KNN	0.11	0.24	1.68	1.04	24.40

Evaluasi model regresi untuk memprediksi Tingkat Pengangguran Terbuka (TPT) berdasarkan Indeks Pembangunan Manusia (IPM) menunjukkan performa prediktif yang sangat terbatas. Dari 10 kombinasi model dan transformasi terbaik (Tabel A.3), nilai koefisien determinasi (R^2) tertinggi hanya mencapai 0.12, yang berarti model hanya mampu menjelaskan 12% variasi TPT. Sisanya, sebesar 88%, dipengaruhi oleh faktor lain yang tidak direpresentasikan oleh IPM.

Mayoritas model dengan performa terbaik adalah K-Nearest Neighbors (KNN), yang muncul dalam 9 dari 10 kombinasi teratas, dengan berbagai transformasi seperti Yeo-Johnson, Log, Box-Cox, Polynomial, Square-root, dan Inverse. Namun, semua model ini menunjukkan nilai error yang sangat serupa, yaitu RMSE ~ 0.24 – 0.25 , MAE ~ 1.04 , dan MAPE $\sim 24.3\%$, menunjukkan tingkat kesalahan yang cukup besar dan homogenitas performa yang mengindikasikan bahwa transformasi data tidak banyak meningkatkan kemampuan prediktif model terhadap TPT.

B. Analisis Kluster

Analisis kluster dilakukan terhadap data provinsi di Indonesia menggunakan tiga indikator utama, yaitu Indeks Pembangunan Manusia (IPM), Tingkat Kemiskinan, dan Tingkat Pengangguran Terbuka (TPT). Seluruh data terlebih dahulu dinormalisasi dengan teknik scaling, lalu dikelompokkan menggunakan metode KMeans++ agar pemisahan antar kluster lebih optimal. Pemilihan jumlah kluster didasarkan pada Elbow Method yang didukung oleh KneeLocator, serta dievaluasi melalui nilai Silhouette Score untuk memastikan kualitas segmentasi.


B.1 Penentuan Jumlah Cluster

Penentuan jumlah kluster optimal merupakan tahap penting dalam analisis K-Means Clustering untuk memastikan segmentasi data yang efektif dan tidak overfitting. Pada penelitian ini, digunakan pendekatan Elbow Method yang mengevaluasi nilai *inertia* untuk setiap nilai k (jumlah

klaster). Nilai inertia dihitung sebagai total jumlah kuadrat jarak antara tiap data dengan pusat klasternya masing-masing, dirumuskan sebagai:

$$Inertia(k) = \sum_{i=1}^k \sum_{x_j \in C_i} \|x_j - \mu_i\|^2$$

di mana C_i adalah klaster ke- i , x_j adalah data ke- j dalam klaster tersebut, dan μ_i adalah centroid klaster i .



Gambar B.1 Grafik Elbow Method

Grafik inersia terhadap jumlah klaster (k) menunjukkan pola menurun yang melandai. Titik elbow menandai jumlah klaster optimal, yakni saat penurunan inertia mulai tidak signifikan. Untuk mengidentifikasinya secara objektif, digunakan algoritma KneeLocator, yang mendeteksi titik perubahan kelengkungan grafik [20]. Hasil menunjukkan elbow berada pada $k = 5$, sehingga digunakan lima klaster dalam analisis ini.

B.2 Hasil Klaster

Dari hasil analisis, diperoleh 5 klaster utama dengan karakteristik sebagai berikut:

Tabel B.2.1 Hasil Klaster

Klaster	IPM	Kemiskinan	TPT
0	79.66	7.42	2.60
1	72.86	7.67	4.16
2	76.34	6.37	6.04
3	70.40	14.55	3.20
4	72.87	15.85	5.94


Dari tabel di atas dapat disimpulkan bahwa data yang digunakan dibagi menjadi 5 klaster yang memiliki profil masing-masing. Berikut merupakan profil dari setiap klaster yang terbentuk:

- 0 : Provinsi dalam klaster ini memiliki IPM sangat tinggi, tingkat kemiskinan rendah, dan tingkat pengangguran sangat rendah.
- 1 : Provinsi klaster ini memiliki IPM menengah ke bawah, tingkat kemiskinan rendah hingga sedang, dan tingkat pengangguran cukup tinggi.
- 2 : Provinsi dalam klaster ini menunjukkan IPM cukup tinggi dan tingkat kemiskinan sangat rendah, namun

menghadapi tantangan pengangguran terbuka yang tinggi.

- 3 : Provinsi dalam klaster ini cenderung memiliki IPM terendah, tingkat kemiskinan tinggi, namun tingkat pengangguran relatif rendah.
- 4 : Provinsi dalam klaster ini memiliki IPM menengah, namun tingkat kemiskinan dan pengangguran keduanya tinggi.

Gambar di bawah menampilkan scatterplot hasil klasterisasi provinsi di Indonesia berdasarkan tiga indikator utama, yaitu Indeks Pembangunan Manusia (IPM), Tingkat Kemiskinan, dan Tingkat Pengangguran Terbuka (TPT). Setiap titik pada grafik merepresentasikan satu provinsi, sedangkan warna yang berbeda menandakan klaster yang terbentuk dari hasil segmentasi menggunakan metode KMeans++.



Gambar B.2.1 Scatterplot Hasil Cluster

Scatterplot ini memperlihatkan distribusi karakteristik yang khas pada masing-masing klaster:

- Klaster 0 (merah) menempati posisi terpisah dengan nilai IPM sangat tinggi, kemiskinan rendah, dan TPT sangat rendah.
- Klaster 1 (biru) didominasi provinsi dengan IPM menengah ke bawah, kemiskinan rendah hingga sedang, dan TPT cukup tinggi.
- Klaster 2 (hijau) berisi provinsi dengan IPM cukup tinggi dan kemiskinan sangat rendah, namun tingkat pengangguran terbuka yang tinggi.
- Klaster 3 (ungu) mencakup provinsi dengan IPM terendah, tingkat kemiskinan tinggi, dan pengangguran relatif rendah.
- Klaster 4 (oranye) terdiri dari provinsi dengan IPM menengah, namun tingkat kemiskinan dan pengangguran sama-sama tinggi.

Visualisasi ini membantu mengidentifikasi pola pengelompokan provinsi secara visual, memperjelas perbedaan karakteristik sosial ekonomi antar klaster, serta mendukung analisis deskriptif dan penentuan strategi

intervensi yang lebih tepat sasaran di masing-masing kelompok.

Kelompok provinsi berdasarkan hasil analisis clustering dapat dilihat pada Tabel berikut. Setiap klaster memiliki karakteristik sosial ekonomi yang berbeda-beda, sebagaimana tercermin dari sebaran provinsi di masing-masing klaster:

Tabel B.2.2 Provinsi Berdasarkan Cluster

Cluster	Provinsi
0	DI Yogyakarta, Bali
1	Riau, Jambi, Sumatera Selatan, Lampung, Jawa Tengah, Jawa Timur, Kalimantan Barat, Kalimantan Tengah, Kalimantan Selatan, Kalimantan Utara, Sulawesi Selatan, Maluku Utara
2	Sumatera Utara, Sumatera Barat, DKI Jakarta, Jawa Barat, Banten, Kalimantan Timur, Sulawesi Utara
3	Bengkulu, Nusa Tenggara Barat, Nusa Tenggara Timur, Sulawesi Tengah, Sulawesi Tenggara, Gorontalo, Sulawesi Barat, Papua Barat
4	Aceh, Maluku, Papua

Tabel di atas menunjukkan hasil pengelompokan provinsi di Indonesia berdasarkan karakteristik Indeks Pembangunan Manusia (IPM), tingkat kemiskinan, dan tingkat pengangguran terbuka (TPT). Setiap klaster memiliki ciri khas serta tantangan pembangunan yang berbeda-beda.

Klaster 0 terdiri dari provinsi-provinsi yang memiliki IPM sangat tinggi, tingkat kemiskinan rendah, dan tingkat pengangguran yang sangat rendah. Daerah seperti DI Yogyakarta dan Bali termasuk dalam klaster ini, yang mencerminkan kualitas hidup dan pembangunan manusia yang sangat baik serta stabilitas sosial-ekonomi yang relatif optimal.

Klaster 1 mencakup provinsi dengan IPM menengah ke bawah, tingkat kemiskinan rendah hingga sedang, namun menghadapi tingkat pengangguran yang cukup tinggi. Wilayah dalam klaster ini memerlukan perhatian khusus dalam penyerapan tenaga kerja dan peningkatan kualitas pendidikan untuk mendorong pembangunan yang lebih merata.

Klaster 2 dihuni oleh provinsi dengan IPM tinggi dan tingkat kemiskinan sangat rendah, tetapi tingkat pengangguran terbuka yang tinggi. Kondisi ini mengindikasikan bahwa meskipun kualitas hidup dan kesejahteraan sudah baik, tantangan utama terletak pada penciptaan lapangan kerja dan pengurangan pengangguran.

Klaster 3 terdiri dari provinsi-provinsi dengan IPM terendah dan tingkat kemiskinan yang tinggi, meskipun tingkat pengangguran relatif rendah. Daerah-daerah dalam kelompok ini menghadapi tantangan besar pada aspek pembangunan manusia dan pengentasan kemiskinan.

Klaster 4 berisi provinsi dengan IPM menengah, namun tingkat kemiskinan dan pengangguran yang tinggi. Wilayah-wilayah dalam klaster ini membutuhkan intervensi menyeluruh, baik dari sisi peningkatan kualitas pendidikan dan kesehatan, maupun dalam menciptakan peluang kerja untuk menurunkan kemiskinan dan pengangguran.

Dengan adanya pengelompokan ini, kebijakan dan program pembangunan dapat diarahkan secara lebih spesifik sesuai kebutuhan dan tantangan utama di masing-masing klaster. Hal ini diharapkan mampu meningkatkan efektivitas upaya pemerintah dalam mempercepat peningkatan kesejahteraan dan pembangunan manusia di seluruh provinsi di Indonesia.

B.4 Evaluasi Model

Evaluasi kualitas model klasterisasi dilakukan dengan menggunakan metrik Silhouette Score, yang mengukur seberapa baik objek berada dalam klasternya masing-masing dibandingkan dengan klaster lain. Nilai Silhouette Score berkisar antara -1 hingga 1, di mana nilai mendekati 1 menunjukkan pemisahan klaster yang sangat baik, sedangkan nilai mendekati 0 menunjukkan klaster yang tumpang tindih, dan nilai negatif mengindikasikan objek lebih dekat ke klaster lain daripada klasternya sendiri.

Tabel B.4 Hasil *Silhouette Score*

<i>Silhouette Score</i>	0.389
-------------------------	-------

Pada hasil analisis ini, Silhouette Score rata-rata untuk lima klaster yang terbentuk adalah 0,389. Nilai ini menunjukkan bahwa hasil klasterisasi berada pada kategori sedang (moderat), yang berarti pemisahan antar klaster sudah cukup baik namun masih terdapat beberapa tumpang tindih antar anggota klaster. Meskipun demikian, nilai ini masih dapat diterima untuk data sosial-ekonomi yang umumnya memiliki variasi dan overlapping antar wilayah.

Nilai Silhouette Score ini juga mengindikasikan bahwa struktur klaster yang terbentuk sudah cukup representatif untuk menggambarkan segmentasi provinsi di Indonesia berdasarkan indikator IPM, tingkat kemiskinan, dan tingkat pengangguran terbuka. Namun, untuk mendapatkan pemisahan klaster yang lebih tajam di masa mendatang, dapat dipertimbangkan penambahan variabel lain atau penggunaan metode klasterisasi yang berbeda sebagai bahan perbandingan.

B.4 Rekomendasi Kebijakan Berdasarkan Klaster

Berdasarkan hasil klasterisasi, setiap kelompok provinsi di Indonesia memiliki tantangan dan kebutuhan yang berbeda-beda. Oleh karena itu, strategi pembangunan harus diarahkan secara spesifik sesuai dengan karakteristik masing-masing klaster.

Pada Klaster 0, yang terdiri dari DI Yogyakarta dan Bali, pemerintah diharapkan dapat mempertahankan serta meningkatkan kualitas pelayanan publik yang sudah baik. Inovasi di bidang pendidikan, kesehatan, dan ekonomi kreatif perlu terus dikembangkan agar kedua provinsi ini tetap menjadi contoh kemajuan pembangunan manusia di tingkat nasional. Selain itu, pengalaman dan keberhasilan dari klaster ini dapat didiseminasikan ke provinsi lain yang masih tertinggal.

Pada Klaster 1, yang berisi provinsi dengan IPM menengah ke bawah dan pengangguran cukup tinggi, fokus kebijakan sebaiknya diarahkan pada peningkatan kualitas pendidikan dan pelatihan kerja yang relevan dengan kebutuhan pasar. Pemerintah daerah perlu memperkuat kerjasama dengan sektor swasta, perguruan tinggi, dan lembaga pelatihan agar lulusan pendidikan benar-benar siap kerja. Selain itu, pembukaan

lapangan pekerjaan baru, terutama di sektor industri, pariwisata, dan ekonomi digital, perlu diprioritaskan untuk menyerap angkatan kerja yang ada.

Untuk Klaster 2, yang beranggotakan provinsi dengan IPM tinggi, kemiskinan sangat rendah, namun tingkat pengangguran terbuka tinggi, pemerintah perlu mendorong kebijakan penciptaan lapangan kerja yang lebih berkualitas dan berdaya saing. Hal ini dapat dilakukan melalui pengembangan sektor usaha baru, start-up, dan pemberian insentif bagi pengusaha muda serta investasi pada industri berbasis teknologi dan jasa. Selain itu, sistem penyaluran tenaga kerja harus terus diperbaiki agar lebih responsif terhadap dinamika pasar.


Pada Klaster 3, yang didominasi oleh provinsi dengan IPM dan tingkat kemiskinan yang rendah tetapi pengangguran juga rendah, upaya yang perlu dilakukan adalah meningkatkan kualitas hidup masyarakat secara menyeluruh. Peningkatan akses pendidikan dan kesehatan dasar harus menjadi prioritas utama, disertai dengan pengembangan ekonomi lokal berbasis potensi daerah, seperti pertanian, perikanan, dan UMKM. Program pemberdayaan masyarakat dan bantuan sosial yang terintegrasi juga sangat diperlukan untuk mengurangi disparitas sosial.

Sementara itu, pada Klaster 4, yang terdiri dari provinsi dengan IPM menengah namun tingkat kemiskinan dan pengangguran sama-sama tinggi, diperlukan intervensi menyeluruh yang melibatkan berbagai sektor. Pemerintah pusat dan daerah harus bekerja sama dalam mengintegrasikan program pelatihan kerja, penguatan jaringan perlindungan sosial, serta pembangunan infrastruktur dasar. Fokus utama adalah meningkatkan akses terhadap pendidikan vokasi dan mempercepat pertumbuhan sektor ekonomi yang dapat menyerap banyak tenaga kerja.

Secara umum, penerapan kebijakan berbasis klaster ini diharapkan mampu meningkatkan efektivitas program pembangunan di Indonesia. Dengan memahami kebutuhan dan tantangan masing-masing kelompok provinsi, alokasi sumber daya dan program intervensi dapat dilakukan secara lebih tepat sasaran, sehingga upaya pengentasan kemiskinan dan peningkatan kualitas hidup masyarakat dapat berjalan lebih optimal dan berkelanjutan.

E. Analisis Geospasial

Analisis geospasial adalah proses mengumpulkan, memproses, dan menafsirkan data yang memiliki referensi geografis atau lokasi tertentu di permukaan bumi. Tujuan utamanya adalah untuk memahami pola, hubungan, dan tren berdasarkan ruang atau lokasi.



Gambar E.1 Peta Rata-Rata Kemiskinan 2022-2024

Berdasarkan hasil analisis geospasial mengenai tingkat kemiskinan rata-rata di Indonesia tahun 2022-2024, tampak adanya disparitas spasial yang signifikan antar provinsi. Wilayah-wilayah di bagian barat Indonesia, seperti Sumatera, Jawa, dan Kalimantan, didominasi oleh warna biru, yang menunjukkan tingkat kemiskinan rata-rata yang lebih rendah, umumnya berada di kisaran 5% hingga 15%. Sebaliknya, bagian timur Indonesia, khususnya Papua dan Papua Barat, ditunjukkan dengan warna merah pekat yang merepresentasikan tingkat kemiskinan tertinggi, yaitu di atas 25%. Provinsi-provinsi di kawasan timur seperti NTT dan Maluku juga menunjukkan tingkat kemiskinan yang cukup tinggi, meskipun tidak setinggi Papua. Peta ini memperlihatkan bahwa isu kemiskinan di Indonesia memiliki dimensi geografis yang kuat, di mana provinsi-provinsi di wilayah timur secara umum mengalami kondisi ekonomi yang lebih tertinggal dibandingkan wilayah barat. Oleh karena itu, kebijakan pengentasan kemiskinan perlu mempertimbangkan pendekatan berbasis wilayah, dengan fokus khusus pada pembangunan infrastruktur, pendidikan, dan akses ekonomi di Indonesia bagian timur.

Analisis geospasial pada penelitian ini melibatkan pemeriksaan hubungan spasial antara variabel-variabel yang dianalisis. Uji Moran digunakan untuk mendeteksi adanya autokorelasi spasial, yang berarti bahwa nilai variabel di satu lokasi cenderung dipengaruhi oleh nilai variabel di lokasi-lokasi yang berdekatan. Uji ini memberikan informasi mengenai apakah pola-pola spasial dalam data tersebut signifikan ataukah hanya kebetulan belaka. Hasil uji ini akan memberikan landasan untuk menentukan apakah analisis model regresi spasial diperlukan.

Tabel E.1 Uji Moran Test

<i>P-Value Moran Test</i>	0.001
---------------------------	-------

Berdasarkan hasil Uji Moran yang menunjukkan p-value sebesar 0.001, dapat disimpulkan bahwa terdapat autokorelasi spasial yang signifikan dalam data. Hal ini mengindikasikan bahwa hubungan antara variabel yang diteliti di lokasi-lokasi tertentu berpengaruh pada lokasi lain yang berdekatan. Oleh karena itu, penerapan model regresi spasial menjadi penting untuk mengakomodasi efek spasial dalam analisis lebih lanjut,

agar hasil prediksi lebih akurat dan mencerminkan pengaruh spasial yang ada dalam data.

Tabel E.2 Metrik Evaluasi Model Regresi Spasial

Model	R ²	RMSE	MSE	MAE	MAPE
SEM	0.26	4.18	17.47	3.15	38.06
SLM	0.24	4.23	17.92	3.14	37.05

Berdasarkan hasil evaluasi yang disajikan dalam tabel E.2, model SEM (Spatial Error Model) menunjukkan performa terbaik dibandingkan dengan model SLM (Spatial Lag Model). Model SEM memiliki R² sebesar 0.26, yang sedikit lebih tinggi dibandingkan SLM yang hanya mencapai 0.24, menunjukkan bahwa SEM dapat menjelaskan sedikit lebih banyak variabilitas dalam data. Selain itu, SEM juga memiliki nilai RMSE yang lebih rendah (4.18) dibandingkan dengan SLM (4.23), menunjukkan kesalahan prediksi yang lebih kecil pada model SEM. Meskipun kedua model memiliki nilai MSE, MAE, dan MAPE yang cukup dekat, SEM tetap menunjukkan hasil yang sedikit lebih baik secara keseluruhan.

Tabel E.3 Hasil Dari SEM

Variabel	<i>P-Value</i>
Rata-rata IPM	0.027
Rata-rata TPT	0.198

Berdasarkan hasil analisis menggunakan model SEM, dapat disimpulkan bahwa Rata-rata IPM memiliki pengaruh yang signifikan terhadap tingkat kemiskinan, dengan nilai p-value sebesar 0.027, yang menunjukkan bahwa hubungan ini tidak terjadi secara kebetulan pada tingkat signifikansi 5%. Artinya, perubahan dalam Rata-rata IPM berpotensi mempengaruhi tingkat kemiskinan secara signifikan. Sementara itu, Rata-rata TPT menunjukkan nilai p-value sebesar 0.198, yang lebih besar dari 0.05, yang mengindikasikan bahwa Rata-rata TPT tidak memiliki pengaruh yang signifikan terhadap tingkat kemiskinan dalam model ini. Oleh karena itu, hanya Rata-rata IPM yang dapat dianggap sebagai faktor yang signifikan dalam menjelaskan variasi tingkat kemiskinan, sementara Rata-rata TPT tidak memberikan kontribusi yang signifikan pada model.

V. KESIMPULAN DAN SARAN

A. Kesimpulan

Analisis regresi yang dilakukan dalam penelitian ini menunjukkan bahwa Indeks Pembangunan Manusia (IPM) memiliki pengaruh signifikan terhadap penurunan tingkat kemiskinan, sedangkan Tingkat Pengangguran Terbuka (TPT) tidak menunjukkan signifikansi dalam model spasial. Model terbaik diperoleh melalui kombinasi transformasi Yeo-Johnson dan Support Vector Regression (SVR) yang menghasilkan nilai R² sebesar 0.55 serta nilai MAE dan MAPE yang relatif rendah. Ini menunjukkan bahwa pendekatan non-linier dan transformasi distribusi mampu menangkap pola yang kompleks dalam data sosial ekonomi. Namun, hubungan antara IPM dan TPT masih tergolong lemah (R² hanya sekitar 0.12), mengindikasikan bahwa peningkatan kualitas manusia melalui pendidikan dan kesehatan belum diiringi secara

langsung oleh penyerapan tenaga kerja yang optimal. Oleh karena itu, intervensi pemerintah dalam bidang ketenagakerjaan perlu dilakukan secara lebih strategis dan spesifik, agar hasil pembangunan manusia dapat dimanfaatkan secara maksimal.

Analisis kluster menggunakan K-Means++ berhasil membagi seluruh provinsi menjadi lima kluster utama berdasarkan kesamaan IPM, TPT, dan tingkat kemiskinan. Setiap kluster memiliki profil sosial-ekonomi yang berbeda-beda, seperti provinsi dengan IPM tinggi dan kemiskinan rendah namun menghadapi tantangan pengangguran tinggi, atau provinsi dengan IPM rendah dan kemiskinan tinggi namun pengangguran yang relatif rendah. Hal ini menunjukkan bahwa pendekatan kebijakan yang seragam tidak akan efektif. Pengelompokan provinsi ke dalam kluster yang serupa memungkinkan perumusan kebijakan pembangunan yang lebih terarah, kontekstual, dan responsif terhadap karakteristik wilayah. Nilai Silhouette Score sebesar 0.389 menunjukkan bahwa struktur kluster cukup memadai untuk menggambarkan segmentasi wilayah Indonesia dalam konteks sosial-ekonomi, meskipun masih terdapat tumpang tindih yang wajar pada data sosial.

Dalam analisis spasial, Uji Moran menunjukkan adanya autokorelasi spasial yang signifikan, artinya kemiskinan di suatu provinsi memiliki hubungan dengan kondisi provinsi di sekitarnya. Oleh karena itu, pendekatan Spatial Error Model (SEM) diterapkan dan menunjukkan bahwa hanya IPM yang berpengaruh signifikan terhadap kemiskinan, dengan p-value sebesar 0.027, sedangkan TPT tidak signifikan. Ini mengindikasikan bahwa faktor spasial penting untuk dipertimbangkan dalam model, terutama karena pola distribusi kemiskinan dan pembangunan manusia cenderung membentuk kluster geografis. Dengan kata lain, kebijakan yang mengabaikan dimensi spasial berisiko menghasilkan intervensi yang kurang tepat sasaran. Oleh karena itu, model spasial seperti SEM dapat memberikan pemahaman lebih akurat dalam menyusun strategi pembangunan yang mempertimbangkan keterkaitan antar wilayah dan potensi efek limpahan (spillover effects).

B. Saran

Berdasarkan temuan bahwa Indeks Pembangunan Manusia (IPM) memiliki pengaruh signifikan terhadap penurunan tingkat kemiskinan, pemerintah pusat dan daerah perlu memprioritaskan kebijakan yang berfokus pada peningkatan kualitas pendidikan, layanan kesehatan, dan standar hidup, terutama di provinsi dengan IPM yang masih rendah. Pendekatan pembangunan berbasis klusterisasi juga menjadi strategi yang relevan untuk diterapkan. Provinsi-provinsi dengan karakteristik sosial ekonomi yang serupa dapat dikelompokkan dan diberi intervensi yang sesuai dengan tantangan utamanya, seperti pengembangan UMKM di daerah dengan kemiskinan tinggi atau penciptaan lapangan kerja di wilayah yang menghadapi pengangguran terbuka yang tinggi. Selain itu, mengingat adanya autokorelasi spasial yang signifikan, penting bagi pemerintah untuk mengintegrasikan model spasial dalam perencanaan pembangunan guna

meningkatkan efektivitas kebijakan, terutama di wilayah yang dipengaruhi oleh kondisi sekitarnya.

Untuk meningkatkan akurasi model prediktif dan efektivitas intervensi kebijakan, penelitian ke depan disarankan untuk menambahkan variabel lain yang relevan seperti belanja pemerintah daerah, tingkat urbanisasi, dan akses terhadap teknologi. Hal ini akan memperkaya pemahaman terhadap faktor-faktor penentu kesejahteraan masyarakat. Di samping itu, pengembangan sistem informasi berbasis geospasial yang terintegrasi juga diperlukan guna memantau perkembangan indikator sosial-ekonomi seperti IPM, pengangguran, dan kemiskinan secara real-time. Sistem ini akan memperkuat kemampuan pemerintah dalam merumuskan kebijakan yang adaptif, responsif, dan berbasis data, baik di tingkat nasional maupun daerah.

DAFTAR PUSTAKA

- [1] E. Septyana, A. Setiawan, and B. Susanto, "Analisis Indeks Pembangunan Manusia Provinsi-Provinsi di Indonesia Menggunakan Indeks Baru Berdasarkan Metode Resampling," *Jurnal Sains dan Edukasi Sains*, vol. 4, no. 1, pp. 9–16, Apr. 2021, doi: 10.24246/juses.v4i1p9-16.
- [2] A. Pengaruh Tingkat Pertumbuhan Ekonomi Jeni Palindangan, A. Bakar, J. Palindangan, and P. Studi Ekonomi Pembangunan Jambatan Bulan, "Analisis Pengaruh Tingkat Pertumbuhan Ekonomi dan Indeks Pembangunan Manusia (IPM) Terhadap Tingkat Pengangguran Di Kabupaten Mimika," vol. 5, 2021.
- [3] M. Paizal, U. Sulia Sukmawati, P. Studi Ekonomi Syariah, F. Ekonomi dan Bisnis Islam, I. Sultan Muhammad Syafiuddin Sambas, and I. Sultan Muhammad Syafiuddin Sambas Email, "Volume 1 Number 2 2021 Analisis Indeks Pembangunan Manusia (Ipm) Terhadap Kemiskinan Di Kalimantan Barat," *JIEF-Journal of Islamic Economics and Finance*, vol. 1, p. 2021, [Online]. Available: <http://e-journal.iainpekalongan.ac.id/index.php/jief/issue/current>
- [4] Rahmadhani, S. (2024). *Pengaruh Inflasi dan Pengangguran Terhadap Kemiskinan dengan Indeks Pembangunan Manusia sebagai Variabel Moderasi di Kota Medan*. Universitas Panca Budi. <https://eprints.pancabudi.ac.id/eprint/3003/1/SUCI%20RAHMADHAN%20Lpdf>
- [5] Kholis, F. N., & Gunarto, T. (2025). *Analisis Pengaruh Kesenjangan Sosial, Indeks Pembangunan Manusia (IPM), dan Pengangguran Terhadap Kemiskinan di Provinsi Lampung (2012–2023)*. eCo-Buss. <https://jurnal.kdi.or.id/index.php/eb/article/download/2243/1153>
- [6] Naufal, R. (2024). *Pengaruh Jumlah Penduduk, Produk Domestik Regional Bruto, Indeks Pembangunan Manusia, dan Tingkat Pengangguran Terbuka terhadap Kemiskinan di Indonesia*. Universitas Sebelas Maret. <https://digilib.uns.ac.id/dokumen/detail/113505>
- [7] Dewintha, A., Yahya, I., & Ihwal, M. (2025). *Analisis Regresi Data Panel Pada Faktor-Faktor Yang Mempengaruhi Tingkat Kemiskinan Di Provinsi Sulawesi Tenggara Tahun 2020-2023*. Arus Jurnal Sains dan Teknologi. <https://jurnal.ardenjaya.com/index.php/ajst/article/view/1165>
- [8] Nurjanah, F. S. (2025). *Tingkat Jumlah Penduduk Miskin di Pulau Sulawesi dan Faktor-Faktor yang Mempengaruhinya (Tahun 2019-2023)*. Universitas Islam Indonesia. <https://dspace.uii.ac.id/handle/123456789/55710>
- [9] A. O. Sihombing, "Analisis Spasial Kemiskinan di Sumatera Utara," *Journal of Analytical Research, Statistics and Computing*, vol. 1, no. 1, pp. 1–10, 2022. [Online]. Available: <https://www.jarsic.org/main/article/view/6>
- [10] W. S. Tarigan, "Analisis Regresi Spasial pada Indeks Pembangunan Manusia di Provinsi Sumatera Utara Tahun 2020," in *Prosiding Seminar Nasional Official Statistics*, Politeknik Statistika STIS, 2021. [Online]. Available: <https://prosiding.stis.ac.id/index.php/semnasoffstat/article/download/896/262>
- [11] D. Wibisono dan H. Susetyo, "Segmentasi Wilayah Berdasarkan Indikator Sosial Ekonomi Menggunakan K-Means Clustering," *Jurnal Informatika*, vol. 15, no. 2, pp. 110–117, 2021. [Online]. Available: <https://jurnal.untan.ac.id/index.php/informatika/article/view/52781>
- [12] Badan Pusat Statistik, "Indeks Pembangunan Manusia menurut Provinsi, 2022 - 2024," 2024. [Online]. Available: <https://www.bps.go.id/id/statistics-table/2/NTQzIzI=/tingkat-pengangguran-terbuka-menurut-provinsi.html>
- [13] Badan Pusat Statistik, "Tingkat Pengangguran Terbuka Menurut Provinsi (Persen), 2022 - 2024," 2024. [Online]. Available: <https://www.bps.go.id/id/statistics-table/2/NTQzIzI=/tingkat-pengangguran-terbuka-menurut-provinsi.html>
- [14] Open Data Jabar, "Persentase Penduduk Miskin Berdasarkan Provinsi di Indonesia (2022–2024)," 2024. [Online]. Available: <https://opendata.jabarprov.go.id/id/dataset/persentase-penduduk-miskin-berdasarkan-provinsi-di-indonesia>
- [15] N. Tshuma and T. Setoboli, "An analysis of the impact of survival entrepreneurship on economic development: A case study of the informal sector in Zimbabwe," *International Journal of Business and Economics*, vol. 19, no. 2, pp. 123–145, 2025. Available: https://www.researchgate.net/publication/391262926_An_Analysis_of_the_Impact_of_Survival_Entrepreneurship_on_Economic_Development_A_Case_Study_of_the_Informal_Sector_in_Zimbabwe
- [16] D. Firoiu, R. Pîrvu, E. Jianu, L. M. Cismaș, and S. Tudor, "Digital performance in EU member states in the context of the transition to a climate neutral economy," *Sustainability*, vol. 14, no. 6, pp. 3343, 2022. Available: <https://www.mdpi.com/2071-1050/14/6/3343>
- [17] A. Rybak, A. Rybak, J. Joostberens, J. Pielot, and P. Tos, "Analysis of the impact of clean coal technologies on the share of coal in Poland's energy mix," *Energies*, vol. 17, no. 13, pp. 1394, 2024. Available: <https://www.academia.edu/download/117567682/energies-17-01394.pdf>
- [18] N. Kuru Alici, A. Arian Dönmez, O. Aktaş, and Z. Zeytun, "The effect of simulation-based breast health education on breast cancer awareness and breast self-examination skills of Afghan refugee women: A randomized controlled trial," *BMC Public Health*, vol. 35, no. 2, pp. ii21–ii30, 2025. Available: <https://link.springer.com/article/10.1186/s12889-025-23313-y>
- [19] Szmuda, T., Ali, S., Hetzger, T. V., Rosvall, P., & Słoniewski, P. (2020). Are online searches for the novel coronavirus (COVID-19) related to media or epidemiology? *International Journal of Infectious Diseases*, 97, 386–390. <https://doi.org/10.1016/j.ijid.2020.06.031>
- [20] V. Satopaa, J. Albrecht, D. Irwin, and B. R. Zdonik, "Finding a 'kneedle' in a haystack: Detecting knee points in system behavior," in *Proc. 31st Int. Conf. Distributed Computing Systems Workshops (ICDCSW)*, Minneapolis, MN, USA, Jun. 2011, pp. 166–171, doi: 10.1109/ICDCSW.2011.20.

Muhammad Yahya Oktaviyanto, Brahmantya Fikri Setya Putra, Ananda Rafi Prasetyo, Rexwald Kamasean, Fadli Muhammad, dan Haryo Bismo Wicaksono adalah penulis dari dokumen tersebut. Semuanya berasal dari Data Science Technology, Airlangga University, Indonesia.